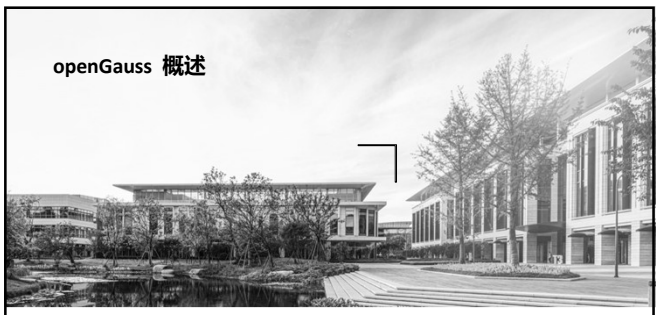

openGauss 概述

HUAWEI

openGauss 目录

- **openGauss 开源社区介绍**
- openGauss 架构
- openGauss 核心技术及实践
- openGauss 未来技术发展方向
- GaussDB(for openGauss)产品介绍
- GaussDB(for openGauss)优势和关键技术
- GaussDB(for openGauss)数据库使用场景

HUAWEI

华为计算商业策略：硬件开放、软件开源、使能合作伙伴

伙伴 | 华为

应用	
中间件	
AI框架	
数据库	
操作系统	
~~整机~~	
~~部件~~	
主板	
华为云	
处理器	

使能合作伙伴

用三年时间让90%的软件跑在鲲鹏上
- 支持合作伙伴应用和软件的迁移

软件开源

将软件利润重分配给新ISV，重新分配软件价值链
- 开源AI 框架MindSpore
- openLooKeng开源数据虚拟化引擎
- openGauss开源数据库（OLTP单机版），构筑鲲鹏数据库生态
- openEuler开源操作系统，使能伙伴操作系统商业发行

硬件开放

降低整机门槛，打破现有格局，重新分配整机价值链
- 提供鲲鹏主板，SSD/网卡/RAID卡等部件，使能伙伴发展自有品牌部件、服务器和PC等

华为聚焦
- 鲲鹏处理器研发，全场景芯片，鲲鹏云服务

HUAWEI

华为GaussDB演进历程

内部自用孵化阶段 → 联创产品化阶段 →共建生态

内部自用 → 产品化 → 云 & 开源 → 生态构建

2001 - 2011	2011 - 2019	2019-2020	2021~
● 企业级内存数据库	• 6行核心数据仓库、DWS华为云商用 • 2行核心业务系统替换商业数据库 • 支撑公司内部40+主力产品，在全球70+运营商规模商用3万+套，服务全球20+亿人口。	• 2019.5.15 GaussDB全球发布 • 构筑合作伙伴生态 • 兼容行业主流生态，完成金融等行业对接 • 2020.6.30 openGauss开源。	• 分享企业级数据管理能力 • 引领生态建设 • 促进数据库教育事业发展

HUAWEI

openGauss产品：商用+自用+开源相结合，内核将长期演进

华为公司内部配套、公有云的GaussDB、开源openGauss 共代码基线

客户

- **公有云/混合云**：金融 | 安平 | 政府 | 运营商 | 大企业
- **华为内部业务**：运营商 | 终端云 | 内部IT
- **合作伙伴**：openGauss系商业发行版

云数据库服务上线
- GaussDB 100云服务（分布式交易型数据库）
- openGauss

计算产业生态
- openGauss ☆

统一内核

GaussDB Kernel开发项目
- 高性能
- 高可用
- 高安全

HUAWEI

openGauss社区：共建生态，共议发展方向

2019.9.19	2020.06.30	2020.07	2020.08	2020.09	2021~
openGauss宣布开源	openGauss源代码正式开放	社区关键组织开始运作	openGauss社区首届Meetup	HC大会伙伴案例发布	openGauss社区认证openGauss社区用户组

openGauss社区组织架构
- 技术委员会
- SIG
- SQLEngine
- StorageEngine
- Connectors
- Docs
- Infra
- Security

openGauss社区角色
- TC：决策社区技术发展方向
- Maintainers：看护项目代码
- Committers：看护代码质量和合入
- Contributors：需求、Bug反馈和开发实现

openGauss社区运营进展

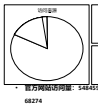

- 官方网站访问量：548459；官方网站访客人数：50675；官方网站安装包下载量：68274
- 微信公众号关注人数：1630；微信社群人数：718
- 社区用户00（安装包下载IP数）：8024
- 社区参与者01（Star、Fork、Watch）：442
- 社区贡献者02（提交Issue和PR）：239

开源协议类型：Mulan PSL v2

HUAWEI

openGauss 定位

把企业级数据库能力带给用户和伙伴

价值 openGauss提供面向多核的极致性能、全链路的业务和数据安全、基于AI的调优和高效运维的能力，全面友好开放，携手伙伴共同打造全球领先的企业级开源关系型数据库；

关键特性

高性能
- **两路鲲鹏性能150万tpmC**
- ① 面向多核架构的并发控制技术；
- NUMA-Aware数据结构；
- SQL-Bypass智能选路执行技术；
- ④ 面向实时高性能场景的内存引擎；

高可用 & 高安全
- 业务无忧，故障切换时间RTO<10s；
- ② 精细安全管理：细粒度访问控制、多维度审计；
- ⑤ 全方位数据保护：存储&传输&导出加密、动态脱敏、全密态计算；

易运维
- ③ 基于AI的智能参数调优，提供AI参数自动推荐；
- 慢SQL诊断，多维性能自监控视图，实时掌控系统性能表现；
- 提供在线自学习的SQL时间预测、快速定位，急速调优；

全开放
- 采用木兰宽松许可证协议，允许对代码自由修改，使用、引用；
- 数据库内核能力完全开放；
- 开放运维监控、开发和迁移工具；
- 开放伙伴认证、培训体系及高校课程

openGauss 目录

- openGauss 开源社区介绍
- **openGauss 架构**
- openGauss 核心技术及实践
- openGauss 未来技术发展方向
- GaussDB(for openGauss)产品介绍
- GaussDB(for openGauss)优势和关键技术
- GaussDB(for openGauss)数据库使用场景

openGauss VS. PG架构和关键技术对比

openGauss架构

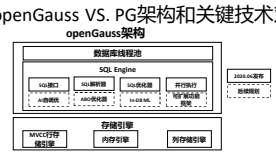

PostgreSQL架构

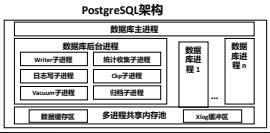

关键差异化因素		openGauss	PostgreSQL
运行时模型	执行模型	线程池模型，高并发连接切换代价小、内存损耗小、执行效率高，一万并发连接比最优性能损耗<5%	进程模型，数据库进程通过共享内存实现通讯和数据共享。每个进程对应一个并发连接，存在切换性能损耗，导致多核扩展性问题。
事务处理机制	并发控制	64位事务ID，使用CSN解决动态快照膨胀问题; NUMA-Aware引擎优化改造解决“五把大锁”	事务ID回卷，长期运行性能因为ID回收周期大幅波动；存在“五把大锁”的问题，导致事务执行效率和多处理器多核扩展性存在瓶颈
	日志和检查点	增量Checkpoint机制，实现性能波动<5%	全量checkpoint，性能短期波动>15%
	鲲鹏NUMA	NUMA改造，cache-line padding，原生spin-lock	NUMA多核能力弱，单机两路性能TPMC ＜60w
数据存储与组织	多引擎	行存、列存、内存引擎，在研DFV存储和原位更新	仅支持行存
查询优化器	优化器	支持SQL Bypass, CBO吸收工行等企业场景优化能力	支持CBO，复杂场景优化能力一般
	SQL解析	ANSI/ISO标准SQL92、SQL99和SQL2003和企业扩展包	ANSI/ISO标准SQL92、SQL99和SQL2003

openGauss 体系结构

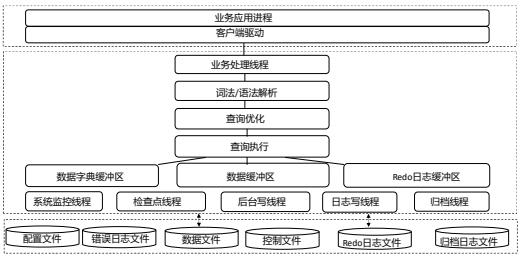

openGauss 逻辑模块

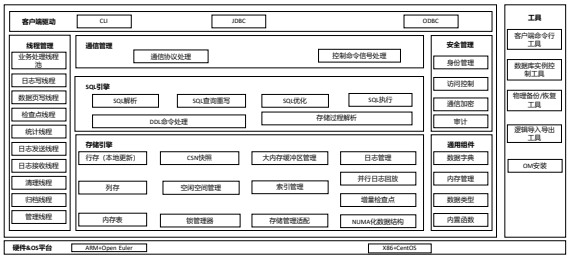

openGauss SQL命令处理流程

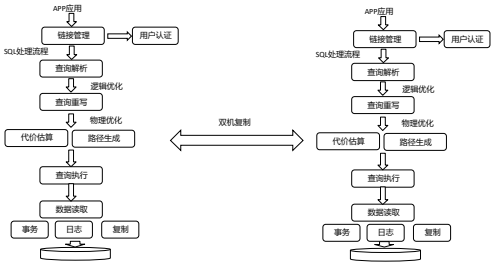

openGauss SQL引擎

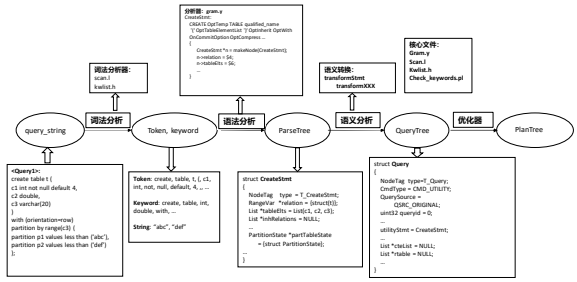

openGauss 查询优化

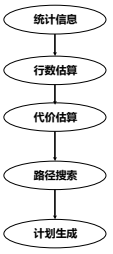

物理优化的依据，来源于表信息的统计

代价估算的基础，来源于基表统计信息的推算

根据关系的行数，推算出当前算子的执行代价

依据若干算子的执行代价，通过求解最优路径进行路径搜索

将查询的执行路径转换成PlanTree能够输出给执行器做查询执行

物理优化的技术点：

1、统计信息模型 Table/Column-Level statistics

描述基表数据的特征包括唯一值、MCV值等，用于行数估算

2、行数估算 Row Estimation

估算基表baserel、Join中间结果集joinrel、Aggregation中结果集大小，为代价估算做准备

3. 代价估算 Cost Estimation

根据数据量估算不同算子执行代价，各算子代价之和即为计划总代价

4. 路径搜索 Access Path Generation

通过求解路径最优算法（e.g. 动态规划、遗传算法）处理连接路径搜索过程，以最小搜索空间找到最优连接路径

openGauss 执行引擎

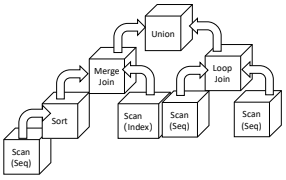

关系数据库本身是对关系集合Relation的运算操作，执行引擎作为运算的控制逻辑主要是围绕着关系运算来实现的，算子可以分成以下几类：

1. **扫描算子（Scan Plan Node）**

   扫描节点负责从底层数据来源抽取数据，数据来源可能是来自文件系统，也可能来自网络。一般而言扫描节点都位于执行树的叶子节点，作为执行的数据输入来源，典型代表SeqScan、IndexScan、SubQueryScan

   关键特征：输入数据、叶子节点、表达式过滤

2. **控制算子（Control Plan Node）**

   控制算子一般不映射代数运算符，是为了执行器完成一些特殊的流程引入的算子，例如Limit、RecursiveUnion、Union

   关键特征：用于控制数据流程

3. **物化算子（Materialize Plan Node）**

   物化算子一般报算法要求，在做算子逻辑处理的时候，要求把下层的数据进行缓存处理，因为对于下层算子返回的数据量不可提前预知，因此需要在算法上考虑数据无法全部放置到内存的情况，例如Agg、Sort

   关键特征：需要扫描所有数据之后才返回

4. **连接算子（Join Plan Node）**

   这类算子是为了应对数据库中最常见的关联操作，根据处理算法和数据输入源的不同分成Mergeioin,SortJoin,HashJoin。

   关键特征：多个输入

openGauss 存储引擎

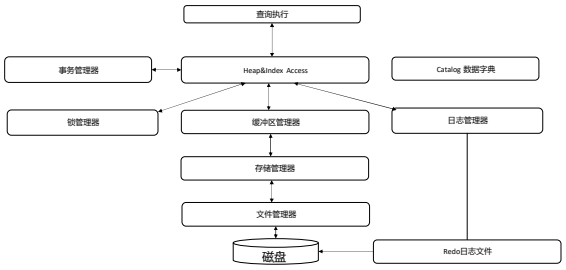

openGauss 目录

- openGauss 开源社区介绍
- openGauss 架构
- **openGauss 核心技术及实践**
  - NUMA多核优化
  - 增量检查点原理
  - MOT内存表原理
  - 极致RTO优化
  - 行列混合引擎
  - AI&DB
  - 线程池原理
  - 全密态等值查询原理
- openGauss 未来技术发展方向

openGauss NUMA CPU结构

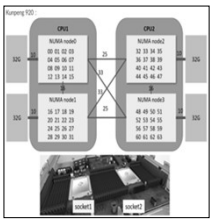

1、NUMA：Non Uniform Memory Access。

2、NUMA距离：NUMA node的处理器和内存块的物理距离。通过numactl工具可以查询到CPU访问的距离信息。

node/ node distances	0	1	2	3
0	10	16	32	33
1	16	10	25	32
2	32	25	10	16
3	33	32	16	10

openGauss NUMA CPU架构数据库的并发问题

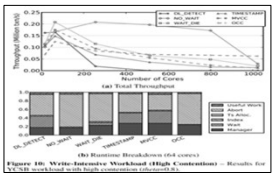

Figure 10: Write-Intensive Workload (High Contention) – Results for YCSB workload with high contention (theta=0.8).

```
[minqi@localhost dtrace]$ ./lwlock_wait.d

          Lock Id            Mode           Count
    CLogControlLock       Exclusive            2085
    CLogControlLock          Shared            2336
      WALInsertLock       Exclusive            3993
      ProcArrayLock          Shared            7400
      ProcArrayLock       Exclusive           34405
       WALWriteLock       Exclusive          205354
         XidGenLock       Exclusive          275126

          Lock Id            Mode   Combined Time (ns)
    CLogControlLock       Exclusive           28956662
    CLogControlLock          Shared           29554120
      WALInsertLock       Exclusive           58710394
      ProcArrayLock          Shared          125250951
      ProcArrayLock       Exclusive          446470964
       WALWriteLock       Exclusive         1944862639
         XidGenLock       Exclusive         4504810482 49
```

1、数据库是高并发，数据访问冲突严重的一些软件系统。数据库领域图灵奖获得者Stonebraker等人于2014年在 VLDB发表的论文：Staring into the abyss: an evaluation of concurrency control with one thousand cores，传统数据库的事务处理机制无法有效利用数十到上百个核处理能力。

2、数据库中存在很多锁，这些锁是性能瓶颈点：Clog、WALInsert、WALWrite、ProcArray、XidGen。

openGauss NUMA 内核数据结构

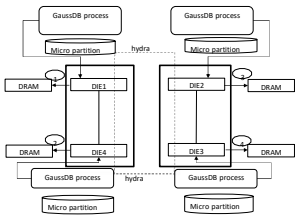

1、线程绑核，避免线程在核间偏移。

2、NUMA化数据结构改造，减少跨核访问。

3、数据分区，减少线程访问冲突。

4、算法调整，减少单点瓶颈。

5、借助ARM原子指令，减少计算开销。

openGauss NUMA 线程绑核

整改前：线程随机调度

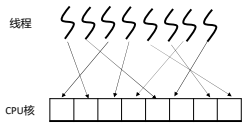

整改后：绑核调度

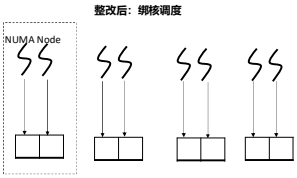

1、网络中断和后台业务线程分开绑核。
2、不同业务线程分开绑核。

openGauss NUMA 化数据结构

整改前：串行加锁拷贝日志

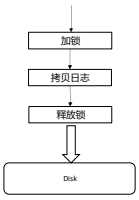

整改后：并行异步拷贝日志

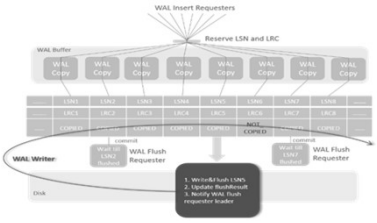

openGauss NUMA数据分区

CLOG 日志即事务提交日志，用来记录事务的最终状态，是XLOG日志的辅助，用来加速通过日志判断事务状态的过程，存在四种事务状态，即： IN_PROGRESS、COMMITED、ABORTED、SUB_COMMITED，每条日志占2 bit，clog 需要存储在磁盘上，一个页面（8k）,按照页面分partition加锁。

整改前：全局唯一的CLOG缓冲池

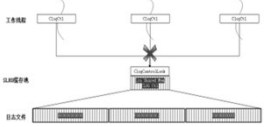

原方案：CLOG的日志缓冲池在共享内存中且全局唯一，名称为 “CLOG Ctl”，各工作线程使用由线程局部变量 ClogCtl 来指向该资源，在高并发的场景下，该资源的竞争成为性能瓶颈

整改后：分区的CLOG缓冲池

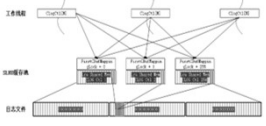

整改后：按pageno将日志均分到多个共享内存的缓冲池中，由线程局部对象的数组 ClogCtlData来记录，名称为“CLOG Ctl ”，同步增加共享内存中的缓冲池对象及对应的全局锁。

openGauss CSN快照

整改前：活跃事务ID快照

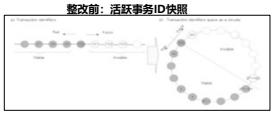

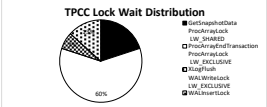

1、事务启动获取事务快照，需要获取ProcArrayLock。
2、事务结束，清理事务状态快照时，需要获取ProcArrayLock。
3、并发连接增大时导致全局事务管理器上获取的快照变大。

整改后：CSN提交快照

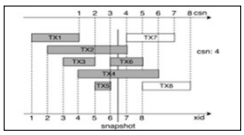

1、上图中每个非只读事务在运行过程中会取得一个XID，在事务提交时会推进CSN，同时会将当前CSN与事务的XID映射关系保存起来。
2、上图中，棕色竖线表示取snapshot时刻，如果不使用CSN方案，那么棕色竖线对应snapshot的集合应该是{2,4,6}。如果采用CSN方案，会获取当前的CSN值，也就是3，事务TX2、TX4、TX6、TX7、TX8的CSN分别为4、6、5、7、8，对于该snapshot而言，这几个事务的修改都不可见。

openGauss 64位事务ID

整改前：32位事务ID

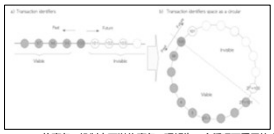

1、32位事务ID机制中可以将事务ID理解为一个循环可重用的序列串。对其中的任一普通XID来说，都有20亿个相对它来说过去的事务，和20亿个未来的事务。可以看出同一个数据库中存在的最旧和最新两个事务之间的年龄差最多是2^31。
为了避免这种问题，需要Vacuum freeze定期的对最旧事务进行回收，以推进该值；当事务ID的差值超过2^31会造成业务中断，强制全库回收事务ID。
2、TP场景事务ID增长迅速，导致32bit事务ID会频繁发生回卷
3、Vacuum机制来回收过老事务ID，效率低，IO开销大。
4、事务ID回收不及时，会导致停库对业务造成严重影响。

整改后：64位事务ID

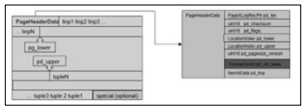

页面头部增加xid base

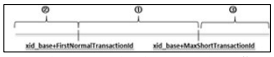

1、解决事务ID回卷问题，防止频繁vacuum对系统造成性能影响
2、64位事务ID特性平滑升级，对现有业务无影响，高效率，低风险。
3、老版本数据页面在页面头部增加xid_base(64bit),避免对页面中的tuple进行修改。

openGauss NUMA ARM原子指令

CAS（Compare and Swap），原子操作，用于多线程操作下，确保数据写入的一致性；
在多线程编程中实现不被打断的数据交换操作，避免同时改写某一数据时由于执行顺序不确定性及中断的不可预知性导致数据不一致问题。

CAS实现方式一：由ldxr和stlxr指令来实现

```
os_compare_and_swap_ulint(&old,old,new);
0x0000000000405c0 <+24>:    ldr     w0, [x29,#24]
0x0000000000405c8 <+32>:    mov     w3, w0
0x0000000000405c4 <+32>:    ldr     w1, [x29,#28]
0x0000000000405c8 <+36>:    add     w0, w0, #0x18
0x0000000000405cc <+40>:    ldxr    w3, [x0]
0x0000000000405d0 <+44>:    cmp     w3, w1
0x0000000000405d4 <+48>:    b.ne    0x4005e0 <main+60>
0x0000000000405d8 <+52>:    stlxr   w4, w1, [x0]
0x0000000000405dc <+56>:    cbnz    w4, 0x4005cc <main+40>
0x0000000000405e0 <+60>:    dmb     ish
```

CAS实现方式二：由casal一条指令来实现

```
//  int *ptr=100;
os_compare_and_swap_ulint(&old,old,new);
4005bc:     b9401ba0        ldr     w0, [x29,#24]
4005c0:     2a0003e2        mov     w2, w0
4005c4:     b9401fa1        ldr     w1, [x29,#28]
4005c8:     910063a0        add     x0, x29, #0x18
4005cc:     2a0293e3        mov     w3, w2
4005d0:     88e3fc01        casal   w3, w1, [x0]
4005d4:     6b02007f        cmp     w3, w2
```

四个指令→1个指令，提升执行效率；

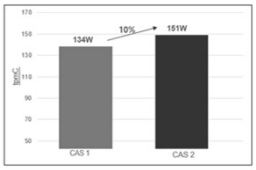

openGauss NUMA 多核优化结果

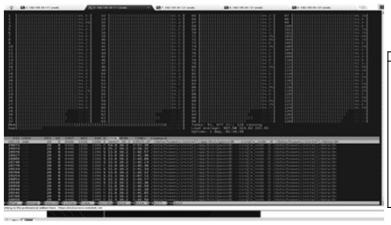

基于鲲鹏920，TPCC测试性能达到150W tpmC。CPU运行效率接近95%。

服务器	项目	型号	数量
Taishan 2280 V2	CPU	Kunpeng 920/64cores / 64threads	2(每个cpu包含64cores,共计128cores)
	主频	2.6Ghz	---
	内存	DDR4,2933 MT/s	512G
	网络	Hi1822	
	磁盘	NVME:3.2T	4
	OS	openEuler-20.03-LTS	1

openGauss 数据库双机企业部署场景

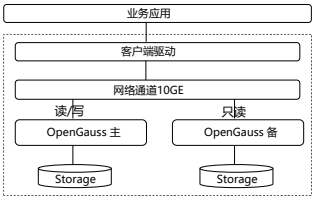

1、最多可能丢失的数据的时长(RPO)：恢复业务系统后与中断时相比的数据损失量，反映恢复数据完整性的指标。

2、系统恢复正常所需要的最大时长(RTO)：业务从中断到恢复正常所需的时间，反映业务恢复及时性的指标。

openGauss 数据库双机原理

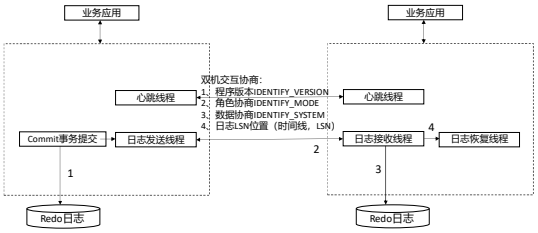

openGauss 数据库极致RTO

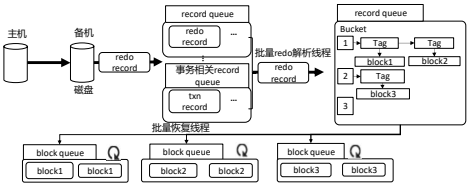

1. 备机日志实时落盘，同时将日志流**并行解码、读取和回放事务日志**；
2. 保证极大化日志回放吞吐，**功能切分服务化、流水线协同**，减少串行度。
3. 批处理化回放，**消除单条回放反复获取/释放锁**的并发控制和IO开销。
4. **页级物理并行**，去除按表切割并行机制，locality更好、并行度更高。

openGauss 数据库RTO时间

在60%负载、70+万tpmC下可达**RTO＜10s（主备切换指令后10秒内，备机接管业务）**。

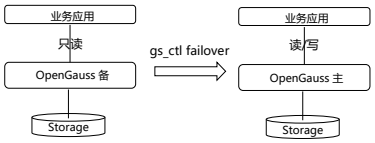

openGauss 大并发业务场景问题

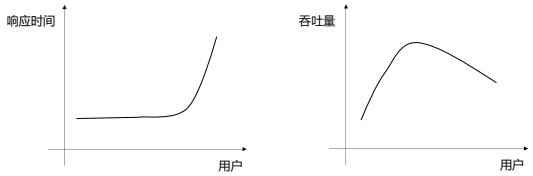

1、连接数越多，后台需要的线程数越多，资源开销越大。

2、在CPU核数固定的情况下，OS调度开销大，不同线程访问数据库资源冲突大。

openGauss 大并发问题解决方案

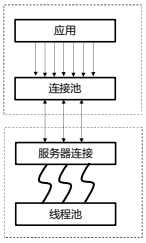

1、连接池一般在客户端设置，连接池避免了连接的频繁创建和销毁。连接复用。

2、线程池在数据库服务器上配置，控制数据库服务器活动线程数目。线程复用。对系统的业务起到流控作用，防止出现雪崩。

3、在高并发场景下，可以将连接池和线程池结合起来使用。

openGauss 线程池实现原理

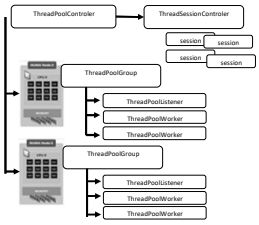

1) 客户端向数据库发起连接请求，PostMaster线程接收到连接请求并被唤醒求。PostMaster线程创建该连接对应的socket，以及创建session数据结构。遍历当前所有的Thread Group，找到当前活跃session数量最少的Thread Group，并把最新的session分发给该Thread Group，加入到该Thread Group 的epoll列表之中。
2) Thread Group的listener线程负责监听epoll列表中所有的客户连接。
3) 客户端发起任务请求，listener线程被唤醒。Listener线程检查当前的Thread Group是否有空闲worker线程，如果有，则把当前session分配给该worker线程，并唤醒该worker线程；如果没有，则把该session放在等待队列之中。
4) worker线程被唤醒后，读取客户端连接上的请求，执行相应请求，并返还请求结果。在一次事务结束（提交、回滚），或者事务超时退出的时候，worker线程的一次任务完成。worker线程将session返回给listener线程，listener线程继续等待该session的下一次请求。worker线程返还session后，检查session等待队列，如果存在等待响应请求的session，则直接从该队列中取出新的session并继续工作；如果没有等待响应的session，则将自身标记为free状态，等待listener线程唤醒。
5) 客户端断开连接时，listener线程被唤醒，关闭连接，同时清理session相关结构，释放内存和io等资源。

openGauss 线程池下大并发性能结果

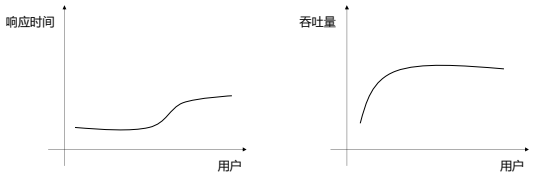

1、高并发下保持性能的稳定性。

openGauss 数据库事务

- **事务的ACID特性**
  - 原子性（Atomicity）：事务所包含的操作要么全部完成，要么什么也没做。
  - 一致性（Consistency）：在一致性数据库上执行事务后，数据库仍需保持为一致性的状态。
  - 隔离性（Isolation）：没有结束的事务在提交之前不允许将其结果暴露给其它事务。
  - 持久性（Durability）：当一个事务的结果提交后，系统保证该结果不会因以后的故障而丢失。
- 范例：银行转账（小张，小李都给小王转账）

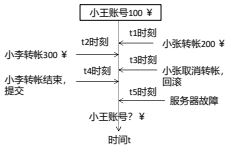

- ACID保障服务器重启后，小王的账号为400 ￥。
- 原子性保障：小张取消转账后，小王账号仍然为100 ￥。
- 一致性保障：小李的账号少300 ￥，小王账号多300 ￥。保证他们两个账号的总和不变。
- 隔离性保障：小张转账的200 ￥对小李不可见，不然结果为700 ￥。
- 持久性保障：服务器故障重启后，小李的转帐仍然是成功的。
- 小王的账号始终为400 ￥。

openGauss 数据库事务机制

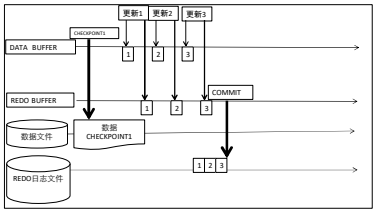

1、事务的持久性（Durability）主要通过预写式日志WAL算法实现。在事务提交时，采用预写式日志方式，把REDO日志写到磁盘。

2、检查点：将脏缓冲队列上的全部数据写出到数据文件。

openGauss 增量检查点技术原理

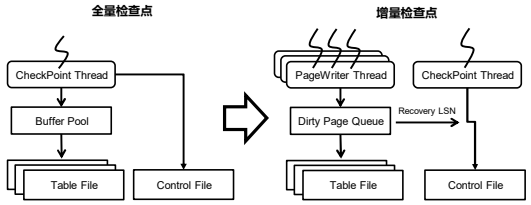

1. 每一个脏数据库块都会被记录到脏页队列，按照第一次对此数据块修改时日志的LSN顺序来排列，如果一个数据块进行多次修改，该数据块在脏页队列中的顺序并不会发生变化。
2. 在执行增量检查点时，把一定LSN之前的脏页刷盘，不需要把所有dirty buffer 全部写到磁盘。

openGauss 增量检查点IO平稳

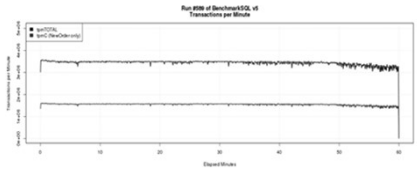

1. IO均分到各个阶段，性能更加平稳。
2. Checkpoint点效率和频率更高，减少宕机恢复时间，降低RTO。

openGauss 企业应用场景OLTP&OLAP

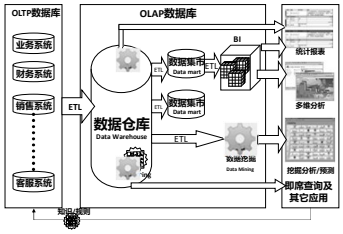

1、**联机事务处理(OLTP)： 存储/检索业务应用中活动的数据以支撑日常的业务活动；**

2、**联机分析处理(OLAP)：存储历史数据以支撑复杂的分析操作，侧重决策支持；**

openGauss 数据库 OLTP&OLAP业务特征

对比维度\ 数据库类型	OLTP	OLAP
用户	操作人员，低层管理人员	决策人员，高级管理人员
功能	日常操作处理	分析决策
事务支持	强事务语义	无/弱事务语义
查询	点查询为主	汇总，关联等复杂查询
插入/更新	大量插入/更新操作， 每次操作1条或很少记录	以批量入库（插入）为主， 很少或没有更新操作
数据内容	管理当前数据	管理历史数据
数据大小	通常几GB到几TB	通常几百GB到几PB

openGauss 行存&列存

Emp_no	Dept_id	Hire_date
1	1	2001-01-01
2	1	2002-02-01
3	1	2002-05-01

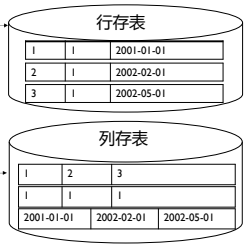

行存（Row Store ）	列存（Column Store）
容易修改记录	修改记录代价高，写一条记录时需要访问多次IO
读取数据代价高，可能读入不需要的列	可以只读取相关的数据
不同记录重复率低，压缩率低	同一列重复值高，压缩率高

openGauss 行列混合引擎

行列混合引擎

表级别指定行存/列存，根据不同的场景选择不同的存储类型。

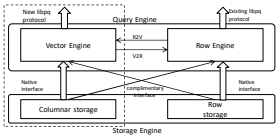

场景	行存	列存	优选
点查询	B+树索引，直接定位到行（页）	粗粒度索引，定位到CU	行存
数据更新	• 支持行级别锁 • 支持cu级别并发更新	支持CU级别锁，支持CU级别并发更新	行存
统计分析	Pipeline执行	天然和向量化引擎对接，降低CPU Cache Miss和指令Miss，效率成倍提升	列存
批量加载	并行批量加载	压缩率高，IO量更小	列存

openGauss 行列混合IoT场景

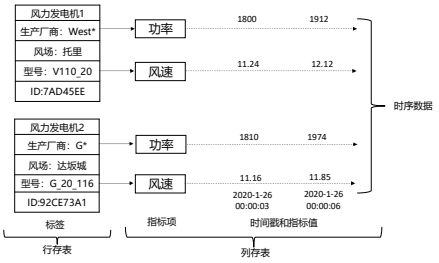

openGauss部署在云上时的安全问题

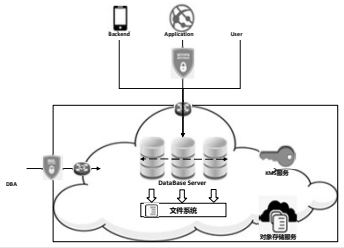

数据库在云上运行时数据存储和访问的安全问题--窃取数据

openGauss 全密态等值查询

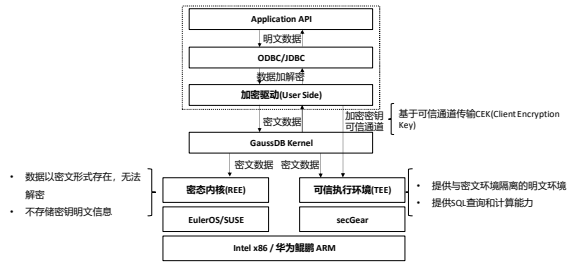

openGauss 全密态等值查询流程

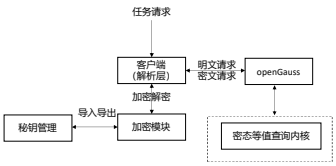

1、三层秘钥管理机制：根秘钥，主秘钥和列加密秘钥。

2、客户端完成数据的加密和解密，服务器完成密态数据计算。

3、不需要加密的字段仍然是明文处理。

openGauss 全密态加密等值数据流程

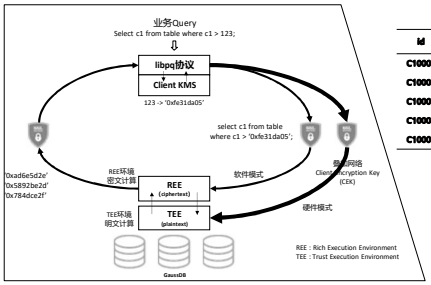

id	c1 (plaintext)	c1 (ciphertext)
C10001	256	0xad6e5d2e
C10002	157	0x5892be2d
C10003	97	0x124f4ed2
C10004	685	0x784dce2f
C10005	58	0x324f4ed2

openGauss 金融风控场景

金融领域风控平台的要求是高并发，低时延，可业务编程。

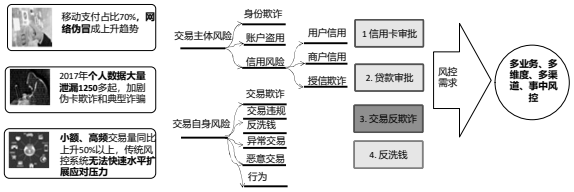

openGauss MOT 风控实时处理

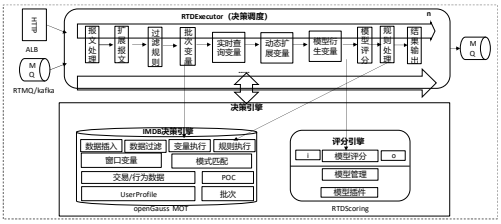

openGauss 磁盘引擎问题

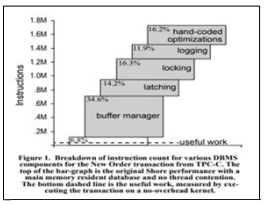

Figure 1. Breakdown of instruction count for various DBMS components for the New Order transaction from TPC-C. The top of the bar-graph is the original Shore performance with a main memory resident database and no thread contention. The bottom dashed line is the useful work, measured by executing the transaction on a no-overhead kernel.

OLTP Through the Looking Glass, and What We Found There

Stavros Harizopoulos, HP Labs, Palo Alto, CA, stavros@hp.com
Daniel J. Abadi, Yale University, New Haven, CT, dna@cs.yale.edu
Samuel Madden, Michael Stonebraker, Massachusetts Institute of Technology, Cambridge, MA, {madden, stonebraker}@csail.mit.edu

1、图灵奖获得者Micheal Stonebraker：磁盘架构70%左右指令在等待锁/闩，仅不到30%CPU做有用功。

2、内存数据库在保证ACID的前提下，以Lock-free无锁方式实现事务处理，能有效规避磁盘架构缺点：

CPU利用率高，一般可达80%以上，提升硬件投资回报；

时延低，没有锁/闩等待，事务处理延迟低，满足实时业务；

openGauss MOT原理

openGauss免锁，高吞吐，低时延

openGauss的融合内存引擎MoT架构

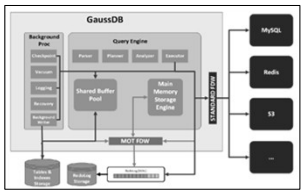

优势1：性能高、CPU利用率高、延迟低

① 高度优化的全内存免锁存储引擎
② 基于全内存优化实现的免锁索引
③ 高度优化的并发访问控制
④ 针对NUMA优化的内存管理，预缓存对象池
⑤ 针对NUMA高度优化的组提交

优势2：生态好、兼容好，功能完整

① 有效利用openGauss现有的查询引擎，兼容PG生态
② 兼容PG原生FDW和索引，SQL标准兼容度高，功能完整
③ 除PG原生FDW之外，还支持存储过程、用户定义函数等功能

openGauss MOT性能

TPCC Throughput on X86-72 vCores

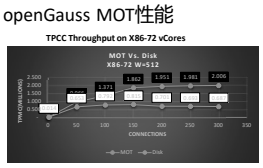

TPCC Latency

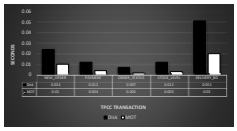

TPCC Throughput on ARM-128 Cores

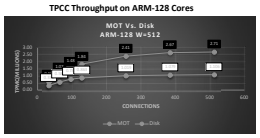

Basic SQL Speed Up

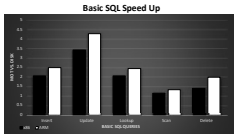

企业数据库运维问题

典型数据库应用系统TCO分布：数据库运维占三分之一左右

DB maintenance cost is biggest part of TCO

Source: IDC 2007.
"Three Year Server TCO. Based on more than 300 interviews conducted across numerous platforms"

日产运维工作占DBA50%以上工作内容
Tuning/upgrading/debugging...

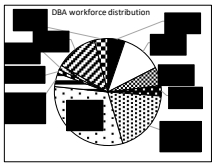

Source: DBA survey from CSDN.

大部分DBA日常工作可以自动化

- schema 设计
- 应用查询开发
- SQL查询优化
- 故障恢复和诊断
- 数据库备份和恢复
- 安全管理
- 数据库扩容和数据迁移
- 数据库部署、补丁、升级
- 监控与故障排查
- OOS部署、补丁、升级
- 服务器、网络、存储日常运维
- 基础设施和资产管理

业务相关　可自动化

openGauss AI 全景

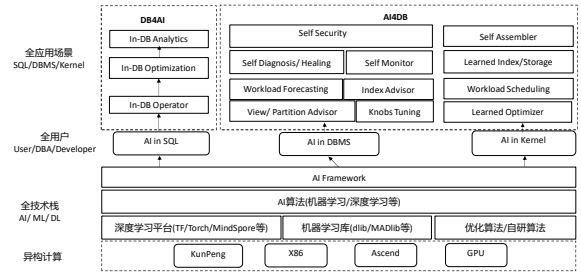

openGauss参数调优与诊断能力

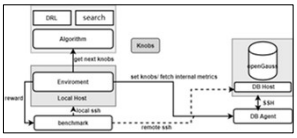

离线参数调优流程概述：

1. 利用长期参数调优总结出的先验规则进行参数配置诊断与生成数据库workload报告；
2. 根据系统的workload、环境信息推荐初始参数配置，包括推荐参数值、建议最大值和最小值（用以保证稳定性，供用户结合自身经验进行选择）；
3. 利用训练好的强化学习模型进行调优，或者使用全局优化算法在给定的参数空间内进行搜索；
4. 常规评价调优效果好坏的方法是跑benchmark获得反馈，调优框架除支持常规benchmark如TPC-C、TPC-H等，还为用户提供了自定义benchmark的框架，用户只需要进行少量工作进行适配即可；目前还在演进支持Performance Model的参数调优，将更进一步加快调优速度；.

在线参数调优流程概述：

1. 采集用户系统内的统计信息和workload，根据训练好的监督学习模型和先验规则，推荐给用户对应的参数配置。

openGauss慢SQL发现能力

使用场景介绍：

1. 上线业务预检测：上线一批新业务前，使用SQL诊断功能评估此次上线业务的预估执行时长，便于用户参考是否应该修改上线业务。
2. Workload分析：对现有workload进行分析，自动分为若干类别，并依次分析此类别SQL语句执行代价，以及各个类别之间的相似程度；
3. SQL透视：能够将workload进行可视化，通过不同颜色和距离远近判断SQL语句之间的相似性，从而供用户直观地分析SQL语句的特点。

SQL透视效果	具备较高的预测准确率	华为云DAS上基于海量数据训练后的SQL透视效果

关键功能：

- 预估SQL语句的执行时间
- 根据SQL语句类型进行类别区分
- SQL语句分布情况的可视化

openGauss数据库监控与异常检测

数据库指标是数据库与用户行为健康的重要标志，数据库中的异常行为可能导致数据库指标产生异常，因此对指标进行有效的监控显得十分必要。

数据库状态监控，指对数据库运行指标进行全方位实时监控。系统能够发现和识别数据库异常以及潜在的性能问题，并及时将数据库异常报告给用户，通过针对各项运行指标的统计分析报告，帮助管理员、运维人员、决策者多视角了解数据库的运行状态，从而更好的应对数据库的需求及规划。

Detection 架构示意图	各个子模块

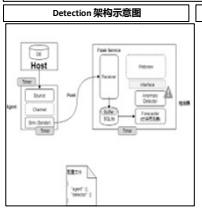

Agent由Source、Channel以及Sink组成。部署在数据库环境上的，用于采集数据库中的性能指标，并通过网络，将其传送给远端检测器模块。

Detector由数据收集Agent推送的数据，并将数据存储在本地磁盘，同时Detector基于时序预测和异常检测等算法对数据库指标进行监控和异常检测。

Receiver：数据接收器，接受Agent.HttpSink数据。同时将接受的数据推送到储存模块。

储存模块：对Receiver中的数据进行储存，目前主要支持数据库方式储存，默认是SQLite数据库。

算法模块：该模块是Detector的核心模块，实现了时序预测、异常检测、告警推送等功能。同时用户可以按照接口要求实现自定义的算法。

openGauss单Query/ Workload级别索引推荐

使用场景介绍：

根据用户的Workload整体信息，为用户推荐需要创建的索引。

使用示例：使用gs_index_advise()推荐索引，性能提高10000倍！

对索引推荐效果的整体评估：

TPC-DS: 降40%左右无明显变化外，其余语句均有不同程度的执行时间缩短；

TPC-C: 与原生索引基本持平，比无索引有巨大性能提升。

	无索引	原索引	算法一	算法二
tpmC	3.22	135.64	134.27	134.49
tpmTOTAL	8.06	299.64	299.24	298.69
Transaction Count	120.67	4495.00	4489.00	4480.67

TPC-C

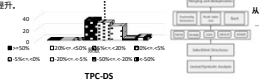

TPC-DS

单Query索引推荐的核心方法：

采用索引设计和优化的相关理论，基于原生的词法和语法解析，对查询语句中的子句和谓词进行分析和处理，再结合字段选择度、聚合条件、多表Join关系等输出最终建议。

索引性能验证的方法：

通过修改优化器相应的数据结构，利用**优化器评估**，进而判断创建该索引后，对优化器生成执行计划的影响。该过程可以不用真正创建索引，即业内所谓的“**假设索引**”，业内也多采用此种方法。

Workload级别索引推荐的核心方法：

通过用户输入（或自主采集）得到的workload信息，根据预设模型，进一步评估创建索引**对整体Workload的影响**，从而从候选索引中筛选出若核心索引。

openGauss DB4AI

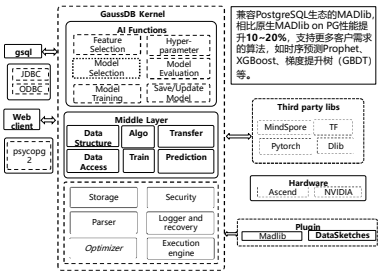

兼容PostgreSQL生态的MADlib，相比原生MADlib on PG性能提升**10~20%**，支持更多客户需求的算法，如时序预测Prophet、XGBoost、梯度提升树（GBDT）等。

组件说明：

1. **自动特征工程**: 从相关的数据表中自动提取有用且有意义的特征，减少了特征工程所需的时间。将周级的处理时间缩短至天级。
2. **模型最优选择**: 在多个模型中，选择出最适合本数据的模型。
3. **超参数优化**: 选出合适模型后，并且能够设定好它的最优参数。
4. **优化算法选择**: 自动地选择出一个优化算法（如SGD、L-BFGS、GD等），以便能够达到效率和精度的平衡。
5. **支持深度学习**: 支持主流深度学习框架。并自动地选择出一个优化算法，以便能够达到效率和精度的平衡。
6. **模型管理**: 记录模型准确度等相关信息。增加模型生命周期管理，支持增量训练、模型更新，支持模型导入和导出。

openGauss 核心技术总结

1、在CPU NUMA 多核的硬件发展趋势下，openGauss通过线程绑核，NUMA化数据结构改造，数据分区和原子指令优化实现150W tpmc。

2、企业可用性指标为RPO和RTO，openGauss支持双机同步保证RPO=0，通过极致RTO技术保证RTO<10s。

3、企业的性能指标为吞吐量和时延，openGauss通过服务器线程池支持企业的高并发，通过增量检查点保证IO性能的稳定性。

4、企业的业务场景为OLTP和OLAP，openGauss通过行列混合引擎同时支持行存和列存，适应企业混合场景。

5、在风控，计费等极端性能企业场景下，openGauss通过免锁内存表，内存索引算法保证高吞吐，低时延，满足企业场景要求。

6、在云化的发展趋势下，openGauss通过全密态实现端到端加密，解决企业上云安全顾虑。

7、通过DB4AI和AI4DB，实现openGauss自运维和调优，减少企业应用开发和维护的TCO。

openGauss 目录

- openGauss 开源社区介绍
- openGauss 架构
- openGauss 核心技术及实践
- **openGauss 未来技术发展方向**
- GaussDB(for openGauss)产品介绍
- GaussDB(for openGauss)优势和关键技术
- GaussDB(for openGauss)数据库使用场景

openGauss未来技术方向：**更智能**、更安全、更高效

We are here

- **AI算法加持，解决传统数据库问题**
  - 索引/视图推荐，如Index Advisor
  - 学习型数据库组件，如Learned Index等
  - 数据库自治运维，如AI-Based Optimizer
- **数据库系统的软硬件故障自诊断与自定位技术**
- **数据库内AI技术**

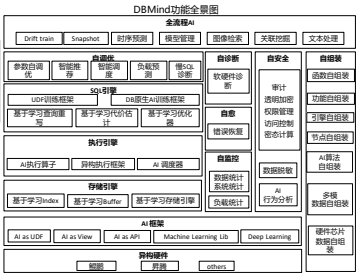

openGauss未来技术方向：更智能、**更安全**、更高效

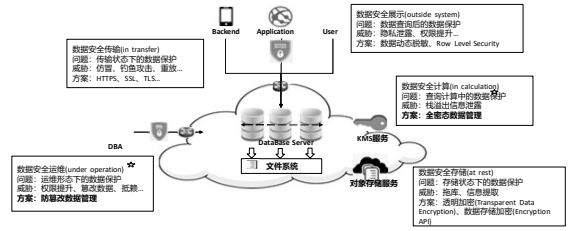

openGauss未来技术方向：更智能、更安全、**更高效**

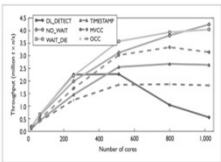

众核系统线性scale-up

- 竞争冲突→Latch-free/wait-free;

	DRAM	PCM	RRAM	MRAM	SSD	HDD
Read latency	60 ns	50 ns	100 ns	20 ns	25 μs	10 ms
Write latency	60 ns	150 ns	100 ns	20 ns	300 μs	10 ms
Addressability	Byte	Byte	Byte	Byte	Block	Block
Volatile	Yes	No	No	No	No	No
Energy/ bit access	2 pJ	2 pJ	100 pJ	0.02 pJ	10 nJ	0.1 J
Endurance	$>10^{16}$	10^{10}	10^{8}	10^{15}	10^{5}	$>10^{16}$

DB结合新硬件整合优化，解决传统架构挑战

- 持久化内存：秒级故障恢复→毫秒级故障恢复

openGauss 目录

- openGauss 开源社区介绍
- openGauss 架构
- openGauss 核心技术及实践
- openGauss 未来技术发展方向
- **GaussDB(for openGauss)产品介绍**
- GaussDB(for openGauss)优势和关键技术
- GaussDB(for openGauss)数据库使用场景

GaussDB(for openGauss)数据库产品介绍

GaussDB(for openGauss)，又称GaussDB(openGauss)，是华为公司自主研发的新一代企业级分布式数据库，支持x86和Kunpeng硬件架构，基于Share-nothing架构，提供高吞吐强一致性事务处理能力、两地三中心金融级高可用能力、分布式高扩展能力、大数据高性能查询能力，应用于金融、电信、政府等行业关键核心系统。

GaussDB(for openGauss) 分布式形态整体架构如下：

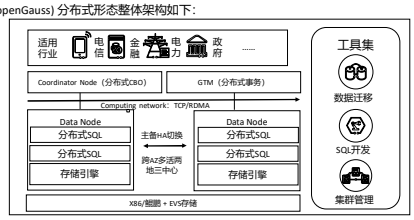

GaussDB(for openGauss) 分布式架构 – 关键角色

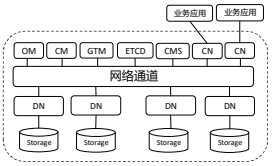

名称	描述
OM	运维管理模块（Operation Manager）。提供集群日常运维、配置管理的管理接口、工具。
CM	集群管理模块（Cluster Manager）。管理和监控分布式系统中各个功能单元和物理资源的运行情况，确保整个系统的稳定运行。
GTM	全局事务管理器（Global Transaction Manager），负责生成和维护全局事务ID、事务快照、时间戳、sequence信息等全局唯一的信息。
CN	协调节点（Coordinator Node）。负责接收来自应用的访问请求，并向客户端返回执行结果；负责分解任务，并调度任务分片在各DN上并行执行。
DN	数据节点（Data Node）。负责存储业务数据（支持行存、列存、混合存储）、执行数据查询任务以及向CN返回执行结果。
ETCD	分布式键值存储系统（Editable Text Configuration Daemon）。用于共享配置和服务发现（服务注册和查找）。
Storage	服务器的存储资源，持久化存储数据。

GaussDB(for openGauss)数据库优势

- 高性能
  - 分布式强制一致事务能力，32节点1500万TPMC；
  - 通过列存储、向量化执行引擎、分布式查询处理等关键技术，实现百亿数据量查询秒级响应。
- 高可用
  - 同城跨AZ容灾，数据不丢失，分钟级恢复。支持两地三中心容灾。
- 高扩展
  - 支持在线扩容，256节点弹性扩展，支撑PB级数据管理能力。
- 高安全性
  - 支持访问控制、加密认证、数据库审计、动态数据脱敏、全密态等安全特性，提供全方位端到端的数据安全保护。

GaussDB(for openGauss):华为自研、开放生态、企业级高性能数据库

定位为企业级云分布式数据库，架构上兼容传统传统数据库的企业级能力和互联网分布式数据库的高扩展和高可用能力

GaussDB(for openGauss)分布式架构

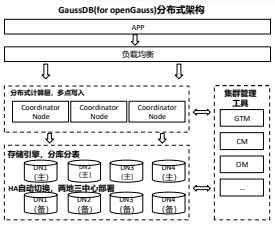

核心优势

① **极致高可用：** 两地三中心架构，跨Region数据实时灾备
② **数据安全：** 实现跨AZ部署数据强一致性，保证数据0丢失
③ **高扩展性：** 容器化部署，性能容量按需水平扩展，高达256节点
④ **性能强劲：** 鲲鹏2路服务器，32节点1500万tpmC（华为内部测试，物理机场景下）
⑤ **全栈软硬自研可控：** 业界领先的鲲鹏+openGauss自研开放内核

支持单分片和分布式两种部署形态

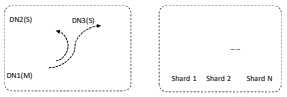

GaussDB(for openGauss):面向核心交易和未来海量事务型场景

GaussDB(for openGauss)单机主备
聚焦企业核心交易场景

GaussDB(for openGauss)

支持Kunpeng的企业级数据库

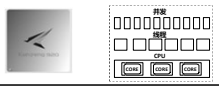

全自研内核、极致性能、极致高可用

openGauss开源社区：https://opengauss.org/zh/

GaussDB(for openGauss)分布式
聚焦海量事务扩展场景

芯片 | 存储 | **数据库** | 大数据 | AI

异构计算框架：端到端多样化算力

分布式关键技术一：高性能--分布式查询引擎

极大的减少用户业务系统迁移到分布式实例上的后台改造工作量

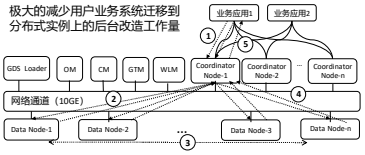

1. 业务应用下发SQL给Coordinator ，SQL可以包含对数据的CRUD操作；
2. Coordinator利用数据库的优化器生成执行计划，每个DN会按照执行计划的要求去处理数据；
3. 数据基于一致性Hash算法分布在每个DN，因此DN在处理数据的过程中，可能需要从其他DN获取数据，GaussDB提供三种stream流（广播流、聚合流和重分布流）实现数据在DN间的流动；
4. DN将结果集返回给Coordinator进行汇总；
5. Coordinator将汇总后的结果返回给业务应用。

关键技术点：

- **基于规则的优化**
  - 视图展开
  - 谓词下推
  - Lazy Aggregation
- **基于代价的优化**
  - 基数估算：Feedback增强、AI基数增强
  - 代价估算：行存/列存代价估算、网络通信代价估算
  - 搜索算法：动态规划方法、遗传算法、AI搜索
- **存储过程执行优化**
  - Global/Local Plan Cache
  - Local Plan Cache
  - PL Pushdown
- **分布式执行计划能力**
  - Light Proxy
  - Fast Query Shipping
  - Remote Query Shipping
- **自研Cascade优化器**
  - 对象化处理规则应用及搜索任务
  - 基于分支限界的剪枝技术

分布式关键技术二：高性能--分布式调度引擎

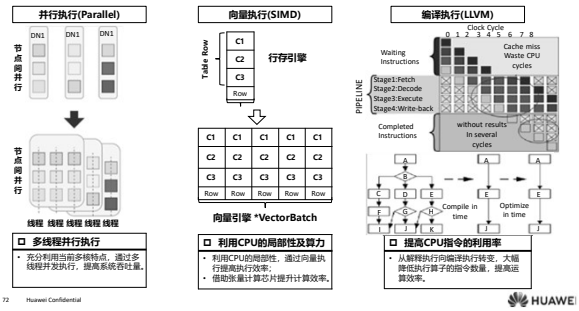

多线程并行执行

- 充分利用当前多核特点，通过多线程并发执行，提高系统吞吐量。

利用CPU的局部性及算力

- 利用CPU的局部性，通过向量执行提高执行效率；
- 借助张量计算芯片提升计算效率。

提高CPU指令的利用率

- 从解释执行向编译执行转变，大幅降低执行算子的指令数量，提高运算效率。

分布式关键技术三：高性能--分布式事务处理性能

- GTM-Lite技术，在保证事务全局强一致的同时，提供高性能的事务处理能力，避免了多分片的性能瓶颈。

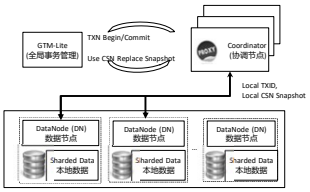

- 高性能事务管理：无锁、多版本、高并发事务技术。
- 分布式强一致：分布式的GTM-Lite方案提供全局事务快照和提交号管理，实现强一致性，且无中心节点性能瓶颈。

分布式关键技术四：高性能--Scale-up能力

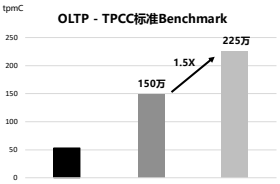

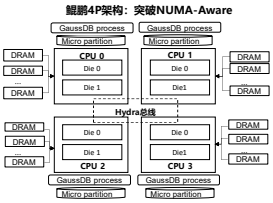

- **NUMA-Aware新架构关键技术**
  - **降低数据缓冲跨DIE访问延迟**：Numa-Aware的Thread to Data内存管理框架；
  - **降低日志写冲突**：Wait-free并行log，新一代日志系统；
  - **降低索引更新冲突**：Latch-free index技术，新一代索引技术。

分布式关键技术五：高可用--集群HA

- 通过硬件冗余、实例冗余、数据冗余，实现整个系统软硬件无单点故障

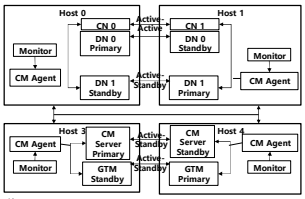

注：
CN: 协调节点；DN：数据节点；GTM：全局事务管理；CM Server：集群管理器；CM Agent：集群管理客户端；Monitor：集群管理监视器；

高可用

硬件高可用：
- ✓ 存储：磁盘RAID冗余。
- ✓ 网络：双交换机冗余。网卡：多网卡冗余。
- ✓ 主机：UPS电源保护。

软件高可用：
- ✓ 协调节点CN实例多活冗余。
- ✓ 数据节点/全局事务管理/ 集群管理器实例Active-Standby冗余。

故障检测

- ✓ 网络故障检测和处理（交换机路由器等）。
- ✓ 网卡故障检测和处理（本地网卡故障检测）。
- ✓ 磁盘故障检测和处理：磁盘心跳，处理文件系统返回的错误码。
- ✓ 主机掉电检测和处理：Heartbeat机制。
- ✓ 集群实例故障检测和处理（CN/DN/GTM进程非法终止）。
- ✓ 集群软件故障。

分布式关键技术六：高可用--跨AZ/Region容灾技术

- 满足金融级容灾场景

节点故障	一主多备，RPO=0,RTO<10s
AZ故障	两地三中心高可用
数据可靠	备份、恢复

极致高可用：两地三中心多活部署

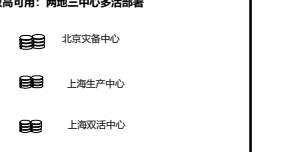

- RTO：同城AZ之间切换时间小于60 s，异地小于10分钟；
- RPO：同城AZ间为0，异地小于10s。

分布式关键技术七：高扩展--Scale-out在线横向扩展

- 拥有卓越的性能线性提升能力

性能、线性增长

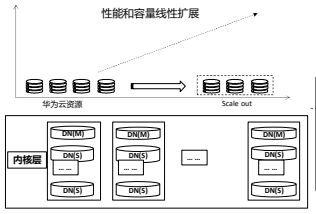

容量、在线扩容

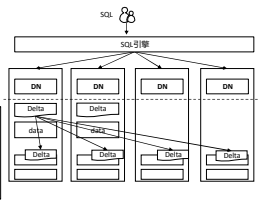

GaussDB(for openGauss) 关键特性总结 (1)

特性维度	特性总结	描述	约束
高性能	高性能事务处理	单节点2路鲲鹏服务器，BenchmarkSQL TPCC，120 w tpmC 2路鲲鹏服务器，BenchmarkSQL TPCC，32节点1500 w tpmC	
高可用	同城跨AZ双活容灾	同城跨AZ双活容灾	规格：RPO=0，RTO ＜ 10s
	两地三中心容灾	1、一套集群同城跨AZ多活容灾 2、两套集群，基于日志异步复制异地容灾	规格：RPO ＜ 10 s，RTO分钟级 约束：实备集群拓扑需要和主机群一致；不支持读；不支持回切
	逻辑备份	表级逻辑备份，roach/gs_dump	
	物理备份恢复	集群级物理备份(Roach)，支持增量备份恢复	规格：RPO ＜ 15 min 约束：不支持PITR
	大版本升级	支持就地升级（全部节点同时升级，中断时间30分钟左右）；滚动升级（在线升级，多次闪断）	规格：滚动升级，单分片中断 ＜ 10 s
	热补丁	在线热补丁，业务零中断	
	在线扩容	在线扩容，扩容过程中支持数据增、删、改、查，及主流DDL操作(Drop/Truncate/Alter table)	规格：扩容是资源不受限，最大1 T/3 h 约束：磁盘使用率仅50%
	支持导出数据至OBS	支持数据导出至OBS，实现云上数据高可靠备份和长周期数据低成本存储	

GaussDB(for openGauss) 关键特性总结 (2)

特性维度	特性总结	描述	约束
高扩展	大规模集群	单集群支持256 分片部署	约束：仅支持非强一致GTM-Free
	单集群支持10w+并发访问	基于线程池技术，实现单节点1 w并发、单集群10 w+并发连接能力	无
企业级能力	故障定界和状态报告（WDR）	性能数据，集群运维监控告警，WDR 诊断报告，active session profile，一键式收集集群诊断信息，计划复现，分布式explain支持	无
高安全	基础安全特性	列级访问控制；网络通信安全特性；控制权与访问权分离；统一审计日志；支持Kerberos	无
	高级安全特性	私有表，动态脱敏，行级访问控制	无
生态兼容	X86	X86：Euler 2.5	无
	鲲鹏	鲲鹏：Euler2.8	无

openGauss 目录

- openGauss 开源社区介绍
- openGauss 架构
- openGauss 核心技术及实践
- openGauss 未来技术发展方向
- GaussDB(for openGauss)产品介绍
- GaussDB(for openGauss)优势和关键技术
- **GaussDB(for openGauss)数据库使用场景**

国有银行案例

- 工商银行B类业务已商用GaussDB(for openGauss)，A2类业务年底商用。

第一阶段
工行实验云部署调试

第二阶段
商密公文系统投产

第三阶段
贵金属业务投产

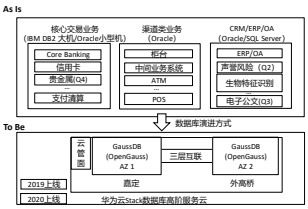

- **高可用：**同城单Region多AZ互联支持同城双活，金融级支持三层组网的管控高可用部署方案；
- **性能线性扩展：**支持集群水平扩展，基本联机性能与Oracle持平；
- **弹性部署：**部署实例及应用要快速响应业务需求，数据库支持容器化部署。

GaussDB 云实现智慧化业务运营

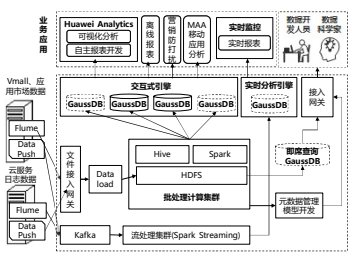

业务诉求和挑战：

华为消费者云大数据平台，集中存储和管理业务侧数据，采用多种数据库混搭架构，其中**运动健康业务**，**云空间业务**；**地理大数据业务**，面临如下挑战：1、运动业务飞速发展，数据年增长30%以上；2、用户智慧化体验要求数据分析平台提供实时分析能力；3、性能提升遇到瓶颈。

解决方案：

将以上业务迁移到GaussDB(for openGauss)分布式数据库之后

1. 按需分片，弹性扩容支撑业务飞速发展。
2. 强大的HTAP混合负载能力，支持业务实时分析。
3. 卓越的线性性能提升，打破传统DIY架构的性能天花板。

用户收益：

1. 按需扩容，节省资源，同时保障业务不中断。
2. 新的数据分析模型上线后，可实时获得分析结果，营销精准率提高50%以上，分析效率提升80%以上。
3. 典型可视化报表查询分析响应时间从过去分钟级降至5s以内，报表开发周期从过去2周降至0.5小时。

openGauss 社区交流

我们希望与各位一起，
共同打造更优秀的国产数据库！
共同构筑良好的国产数据库生态！

微信公众号

添加微信小助手
即可加入官方社群交流

官网：https://opengauss.org
邮箱：contact@opengauss.org

Thank you.

把数字世界带入每个人、每个家庭、
每个组织，构建万物互联的智能世界。

Bring digital to every person, home, and
organization for a fully connected,
intelligent world.

Copyright©2020 Huawei Technologies Co., Ltd.
All Rights Reserved.

The information in this document may contain predictive statements including, without limitation, statements regarding the future financial and operating results, future product portfolio, new technology, etc. There are a number of factors that could cause actual results and developments to differ materially from those expressed or implied in the predictive statements. Therefore, such information is provided for reference purpose only and constitutes neither an offer nor an acceptance. Huawei may change the information at any time without notice.

HUAWEI