2023 知识工程Report1

基于实现指代消解

俞乐楠 1120221303

2024/4/23

一、问题数据处理

在处理 1998-01-2003.txt 文件时，我们首先使用 remove-blankline.py 脚本去除了文件中的空行，以确保数据的整洁性。这个过程包括读取原始文件内容，移除空白行，并将清洗后的内容保存到新文件 1998-01-2003-cleaned.txt 中。

对于数据标注错误，我们遇到了几种特殊情况。一些 JSON 文件中的 indexBehind 值超过了文本文件中相应句子的分词数量。在这种情况下，我们自动将这些超出的下标调整为该句子的最大下标。此外，如果 JSON 文件内容为 None 或者 JSON 文件中的 taskID 在文本中不存在，我们则跳过这些文件，不进行处理。这些措施有助于避免数据处理错误，确保模型训练的数据质量。

二、模型选择

2.1.模型选择

在实现指代消解任务时，我们选择了逻辑回归模型。逻辑回归是一种经典的二分类模型，它通过线性方程来预测一个事件的发生概率。

模型基础

在这个任务中，我们将每个句子的特征视为一个向量，这些向量作为逻辑回归模型的输入。逻辑回归通过下面的线性方程来预测一个事件的发生概率：

$$\text{Logit}(p) = \mathbf{X}\mathbf{W} + b$$

其中，`X`是输入特征矩阵，`W`是模型的权重，`b`是偏置项。

概率转换

逻辑回归模型的输出通过sigmoid激活函数转换成概率，适用于处理0到1之间的概率输出。对于给定的输入向量`x`，sigmoid函数定义如下：

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

这样，线性模型的输出被“压缩”在0到1之间，可以直接解释为概率。

损失函数

为了训练这个模型，我们使用交叉熵损失函数，这在二分类问题中特别有效。交叉熵损失可以衡量实际标签和预测概率分布之间的差异，为模型提供了一个明确的梯度来优化。在二分类问题中，交叉熵损失定义为：

$$L = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right]$$

其中，`y_i`是真实标签，`ŷ_i`是预测概率，`N`是样本数量。

评估指标

针对这个具体问题，虽然准确率（Accuracy）是一个直观的指标，但它不能很好地反映模型在非平衡数据集上的表现。因此，除了准确率，我们还使用了F1分数，它是查准率（Precision）和查全率（Recall）的调和平均数，更适合评估少数类的识别性能。此外，为了全面评估模型的性能，我们还计算了AUC值，它衡量模型区分正类和负类的能力。

2.2.模型训练

特征提取

在实现指代消解任务时，我们选择了基于词向量的特征提取方法。这种方法通过将每个词映射到一个固定长度的向量空间中，可以捕捉到词之间的语义和语法信。对于语料中的每个句子和相应的JSON标注，提取与指代消解相关的特征，如词与指代词之间的距离、词性标记等。使用DictVectorizer进行

向量化，将特征字典转换为机器学习模型可以处理的格式。。

2.3.参数调节及选择原因

在优化逻辑回归模型的超参数过程中，我们分析了不同参数的影响并选择了最适合的配置。下表总结了我们选择的参数及其原因：

参数	选择	原因
Solver	`liblinear`	在小型数据集上表现最佳，适合处理二分类问题，计算效率高，且更适合稀疏数据集。
类权重	`balanced`	自动补偿数据集中的类不平衡，提高模型对少数类的识别能力，增强模型的公平性和有效性。
迭代次数	合适的值	较高的迭代次数提高了模型的准确度，但也增加了过拟合的风险。 中等的迭代次数在准确率和训练效率之间达到平衡。
正则化参数	`C=1`	默认值提供了防止过拟合与保持模型复杂度之间的良好平衡。在我们的数据集上，不同的 `C` 值对模型性能的影响并不显著，因此选择标准值以维持模型的稳定性。

以下图表展示了各超参数调节的影响：

- 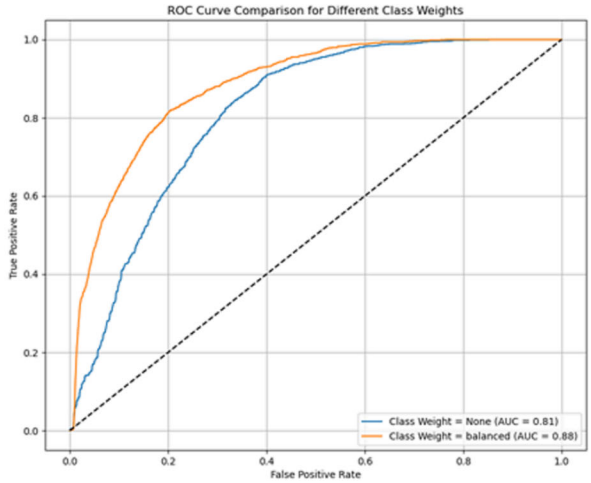

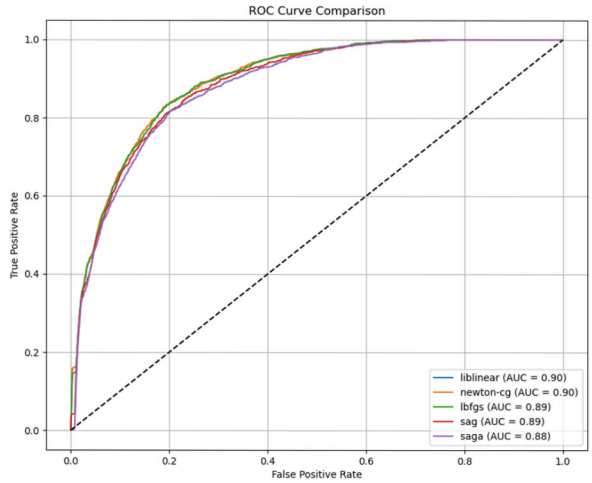

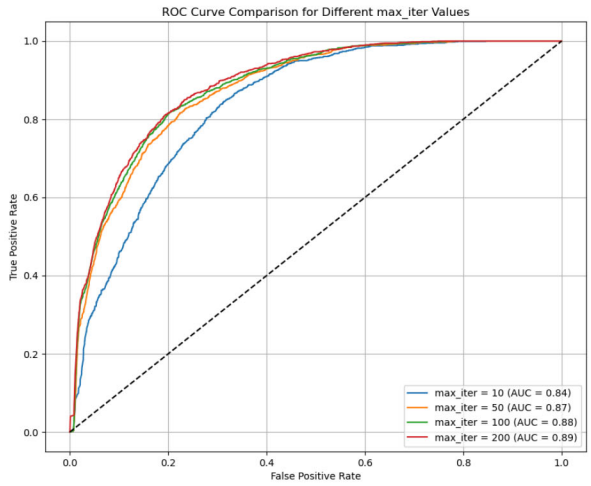

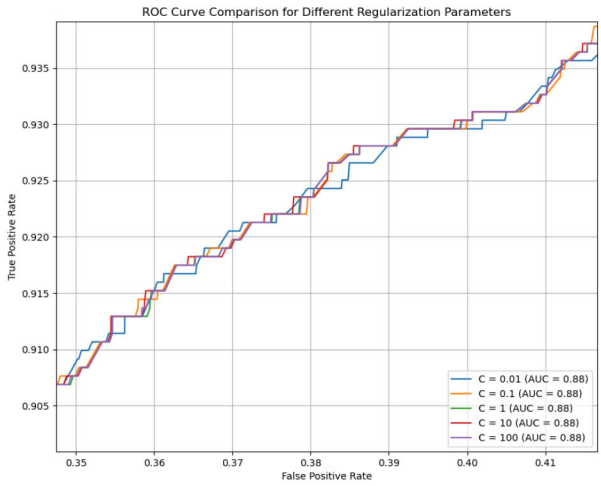

这些参数选择基于提升模型整体性能的目标，同时确保模型在不同使用场景下都能保持良好的泛化能力。

三、模型评估

3.1.F1分数

为了评估模型在非平衡数据集上的性能，我们使用了F1分数作为评估指标。F1分数是精确度和召回率的调和平均数，可以综合考虑模型的查准率和查全率。在二分类问题中，F1分数的计算公式为：

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

其中，`Precision`和`Recall`分别表示模型的查准率和查全率。

- 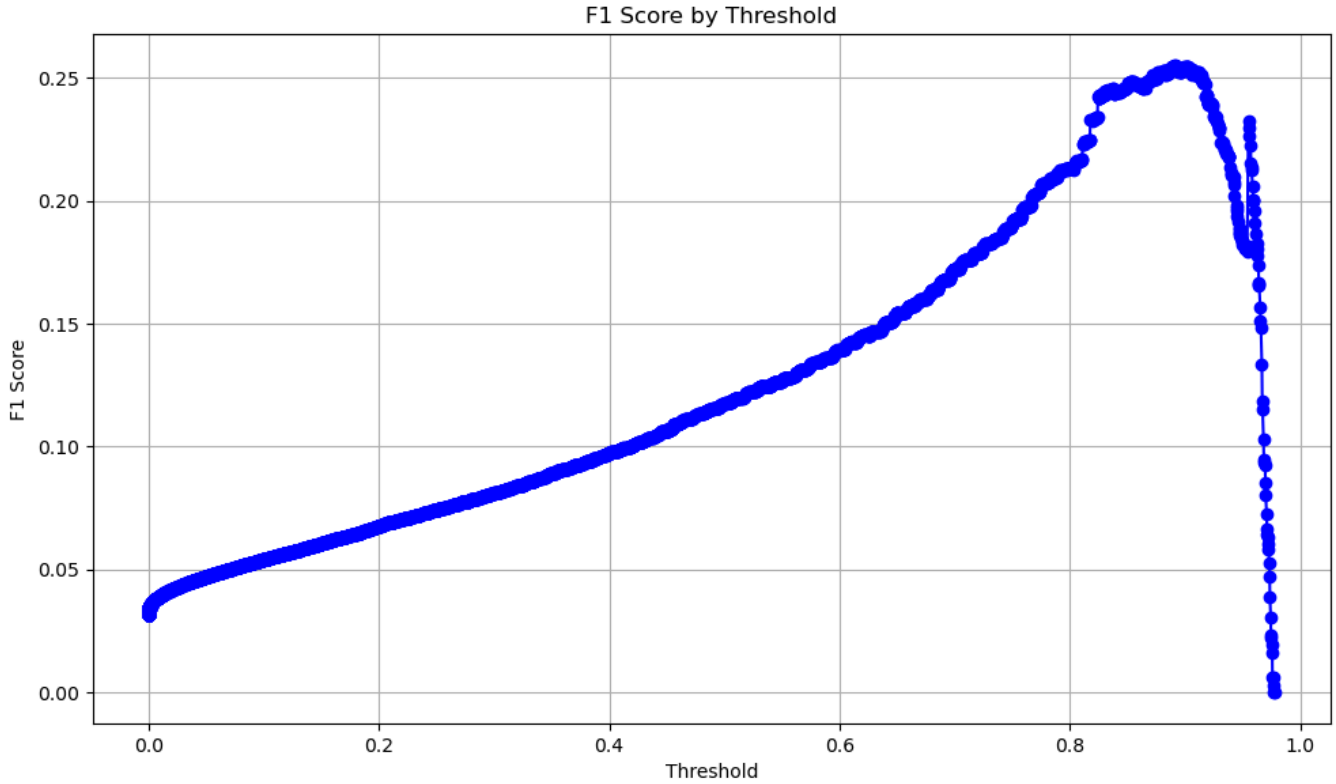

3.2.ROC-AUC曲线

为了全面评估模型在非平衡数据集上的性能，我们使用了ROC-AUC曲线。ROC-AUC曲线是接收者操作特征（ROC）曲线下的面积，可以衡量模型区分正类和负类的能力。在二分类问题中，ROC-AUC曲线的计算公式为：

$$AUC = \frac{1}{2} \times (\text{Recall}_+ - \text{Recall}_-)$$

其中，`Recall_+`和`Recall_-`分别表示正类和负类的召回率。

- 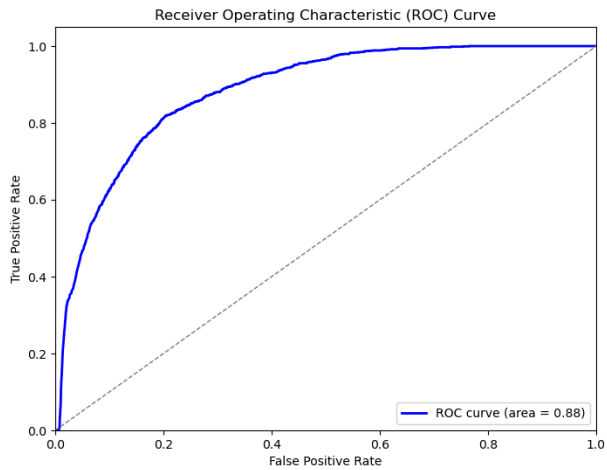

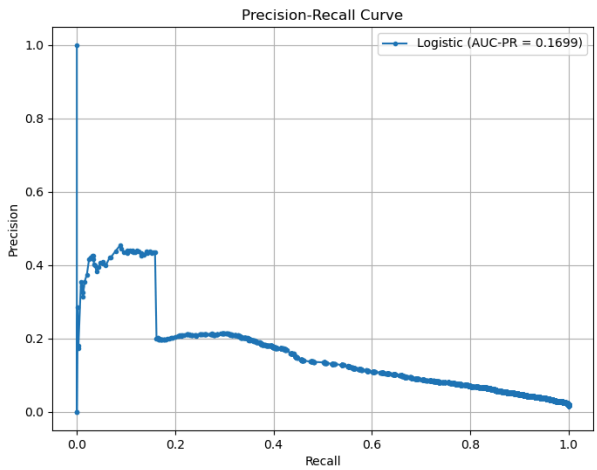

3.3.PR曲线

为了更直观地评估模型在非平衡数据集上的性能，我们使用了PR曲线。PR曲线是精确度-召回率曲线，可以显示模型在不同的召回率水平下的准确率。在二分类问题中，PR曲线的计算公式为：

$$\text{Precision}(p) = \frac{TP}{TP + FP}$$

$$\text{Recall}(r) = \frac{TP}{TP + FN}$$

其中，`TP`表示真正例数，`FP`表示假正例数，`FN`表示假反例数。

3.4.学习曲线

为了评估模型在训练集上的性能，我们使用了学习曲线。学习曲线是一种可视化工具，可以显示模型在训练集上的准确率随训练样本数量的变化情况。通过绘制学习曲线，我们可以观察模型在训练集上的性能变化，并确定模型是否过度拟合或欠拟合。

可以看出当样本数量较小时，模型在训练集上的准确率较低，但随着样本数量的增加超过100000时，模型逐渐收敛到较高的准确率。这表明模型在训练集上存在过拟合问题，需要进一步优化模型以减少过拟合。

- 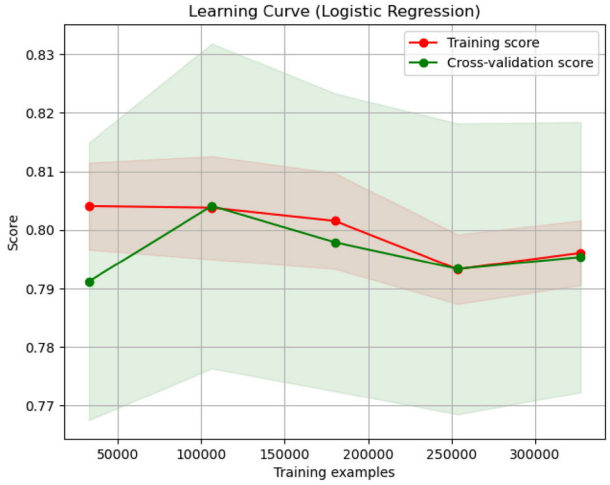

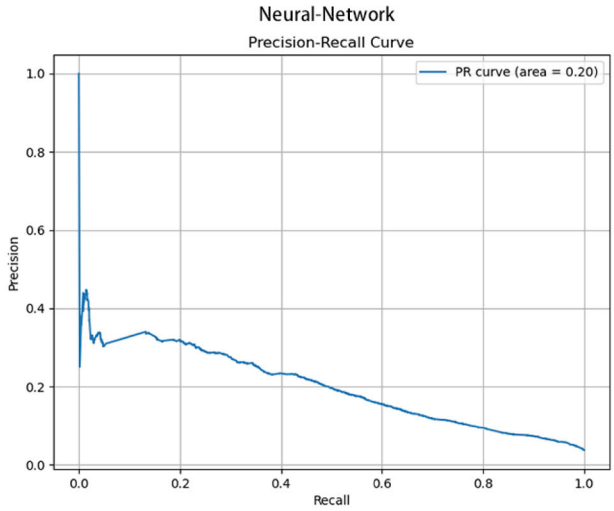

四、模型优化

4.1.神经网络

在实现指代消解任务时，我们选择了神经网络模型作为进一步优化的尝试。神经网络是一种广泛应用于深度学习领域的模型，它由多个神经元层组成，可以捕捉到数据中的复杂模式和特征。

结果

从上图中可以看出，使用神经网络模型进行进一步优化后，模型的准确率有了显著提升。这表明神经网络模型在处理指代消解任务时具有更好的性能。

五、GLM模型的优缺点

广义线性模型（GLM）是统计学中用于数据分析的常见工具，特别是在处理不同类型的分布数据时。尽管GLM在许多应用中非常有用，但它们也有一些局限性。

优点

1. **灵活性**：GLM允许响应变量具有除正态分布以外的分布，例如二项式、泊松或伽马分布，这使得GLM可以应用于各种各样的数据分析场景。
2. **可解释性**：GLM模型保持了线性回归的易于解释的特点，模型系数可以直接解释为影响力或变化率，这对于商业和科研领域的决策支持非常有价值。
3. **广泛的应用**：GLM被广泛应用于医学、生物学、工程学以及社会科学等多个领域，尤其是在预测和控制研究中。

缺点

1. **假设限制**：GLM需要基于分布的假设，例如误差项的独立性和分布特性。如果这些假设被违反，模型的有效性和准确性可能会受到影响。
2. **过拟合风险**：与所有统计模型一样，GLM也可能面临过拟合的问题，特别是当模型过于复杂或数据点过少时。
3. **对异常值敏感**：GLM对异常值比较敏感，异常数据点可以显著影响模型估计和预测。