2024 知识工程Report2

基于神经网络进行特征提取实现指代消解

俞乐楠 1120221303

2024/5/19

一、模型选择

1.1. 模型选择

在本项目中，我们选择使用神经网络模型来实现指代消解任务。神经网络是一种强大的非线性模型，能够通过多层神经元的连接来捕捉数据中的复杂关系。在本项目中，我们使用了一个简单的多层感知器（MLP）模型，包含以下层次结构：

1. **输入层**：接受特征向量作为输入。
2. **隐藏层1**：包含64个神经元，激活函数为 ReLU（Rectified Linear Unit）。
3. **Dropout层**：以0.5的概率随机丢弃一些神经元，以防止过拟合。
4. **隐藏层2**：包含32个神经元，激活函数为 ReLU。
5. **Dropout层**：以0.5的概率随机丢弃一些神经元。
6. **输出层**：包含1个神经元，激活函数为 sigmoid，输出样本属于某一类别的概率。

神经网络模型

模型结构

- **输入层**：特征向量 X
- **隐藏层1**：64个神经元，ReLU激活函数
- **Dropout层**：丢弃概率为0.5
- **隐藏层2**：32个神经元，ReLU激活函数
- **Dropout层**：丢弃概率为0.5
- **输出层**：1个神经元，sigmoid激活函数

激活函数

在隐藏层中，我们使用 ReLU 激活函数，定义为：

$$\mathrm{ReLU}(z) = \max(0, z)$$

在输出层，我们使用 sigmoid 激活函数，将网络的输出值转换为一个概率值，定义为：

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

损失函数

我们使用二元交叉熵损失函数（binary cross-entropy loss），定义为：

$$J(\theta) = -\frac{1}{m}\sum_{i=1}^{m}\left[y^{(i)}\log(\hat{y}^{(i)}) + (1-y^{(i)})\log(1-\hat{y}^{(i)})\right]$$

其中，$\hat{y}$ 是模型的预测输出，y 是实际标签。

优化器

我们选择 Adam 优化器进行模型训练，其更新规则如下：

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\nabla_\theta J(\theta)$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2)(\nabla_\theta J(\theta))^2$$

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}$$

$$\hat{v}_t = \frac{v_t}{1-\beta_2^t}$$

$$\theta = \theta - \eta\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon}$$

其中，β_1 和 β_2 是动量参数，η 是学习率，ϵ 是一个小常数。

评估指标

针对这个具体问题，虽然准确率（Accuracy）是一个直观的指标，但它不能很好地反映模型在非平衡数据集上的表现。因此，除了准确率，我们还使用了F1分数，它是查准率（Precision）和查全率（Recall）的调和平均数，更适合评估少数类的识别性能。此外，为了全面评估模型的性能，我们还计算了AUC值，它衡量模型区分正类和负类的能力。

1.2.模型训练

在模型训练过程中，我们采用了一系列步骤来确保模型的有效性和性能。以下是详细的训练过程：

特征提取

我们为每个词提取了以下特征：

- **距离特征**：候选词与代词之间的距离。
- **词性特征**：候选词的词性。
- **是否为代词**：候选词是否为代词。

这些特征被输入到神经网络中，用于判断每个候选词是否为先行词。

二、模型参数调节

2.1. 参数调节及选择原因

在优化神经网络模型的过程中，我们分析了不同参数对模型性能的影响，并选择了最合适的参数配置。下表总结了我们选择的参数及其原因：

- 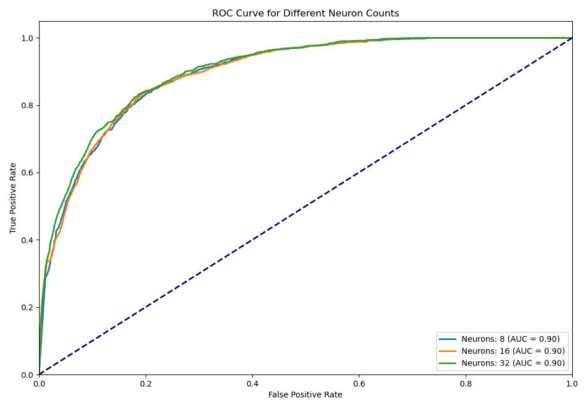

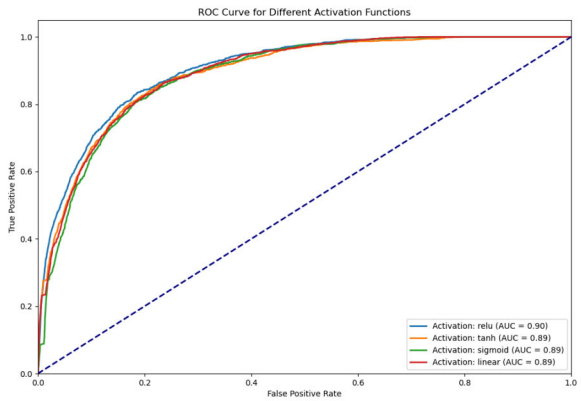

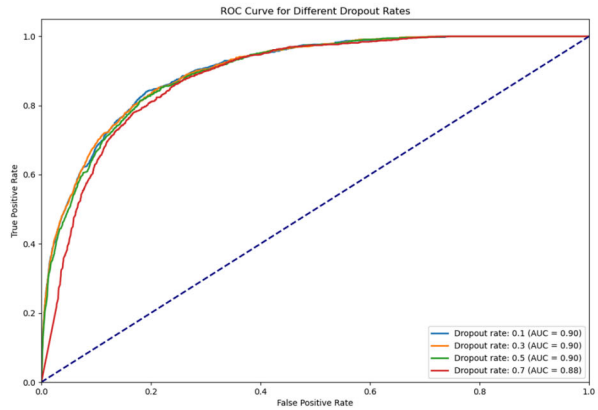

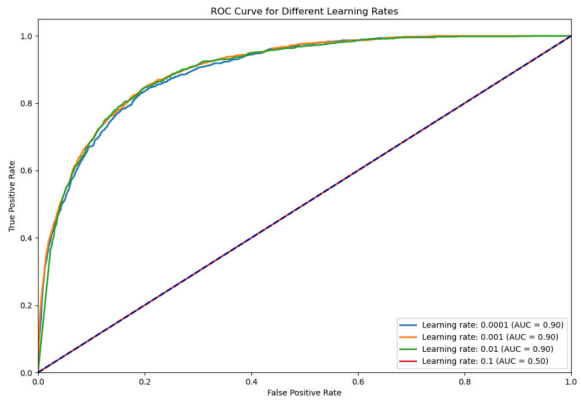

2.2. 参数调节

为了找到最优的神经网络配置，我们尝试了不同的参数组合，并使用交叉验证（cross-validation）来评估模型的性能。通过调整参数，我们发现以下参数配置能够取得最好的性能：

参数	选择	原因
神经元数量	16	16个神经元可以满足该模型的需求，模型容量适中， 能够有效捕捉数据中的模式，显著提升性能， 故选用16个神经元。
激活函数	relu, tanh, sigmoid, linear	ReLU激活函数在处理非线性问题时表现良好， 能够有效缓解梯度消失问题。
Dropout比例	0.1	通过添加Dropout层防止过拟合， 选择0.1的比例能够在保留足够神经元的同时减少过拟合风险。
学习率	0.0001	较低的学习率能够使模型更稳定地收敛， 避免出现震荡和发散的问题。
损失函数	Binary Crossentropy	二分类问题的常用损失函数，适用于处理二分类问题， 能够有效优化模型性能。
优化器	Adam	Adam优化器在处理稀疏梯度和处理大规模数据时表现出色， 且收敛速度较快，选择其作为优化器能够提高训练效率。
训练轮数	3	在初步实验中发现3个epoch能够达到收敛， 避免过长时间训练导致的过拟合。
批次大小	32	批次大小越大运行速度越快，并且对实验结果影响不大， 每批越多时速度越快， 选择32在运行速度和准确度之间找到了一个平衡。

这些参数的选择是基于对模型性能的实验结果进行分析后确定的，目的是在保证模型精度的同时，避免过拟合并提高训练效率。通过调整这些参数，我们能够找到最适合当前数据集和任务的神经网络配置。

- 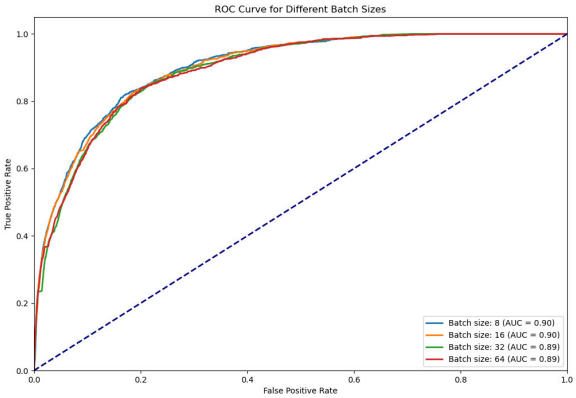

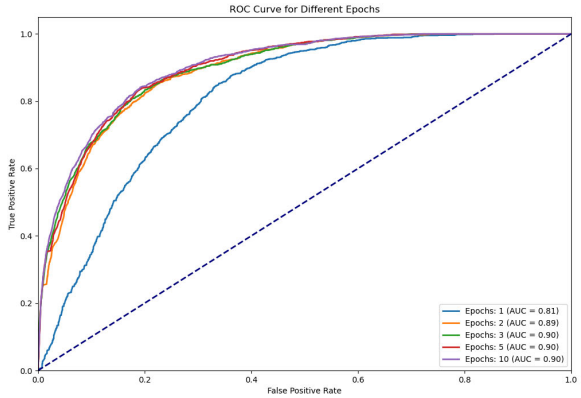

三、模型评估

3.1.F1分数

为了评估模型在非平衡数据集上的性能，我们使用了F1分数作为评估指标。F1分数是精确度和召回率的调和平均数，可以综合考虑模型的查准率和查全率。在二分类问题中，F1分数的计算公式为：

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

其中，`Precision`和`Recall`分别表示模型的查准率和查全率。

- 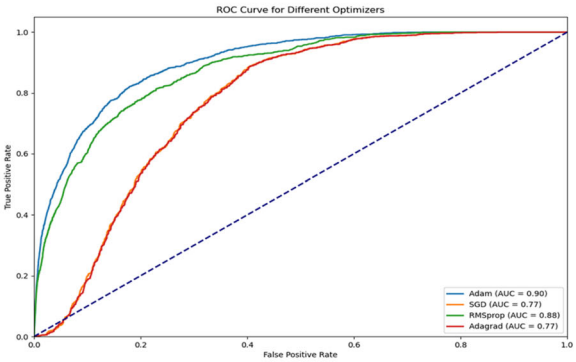

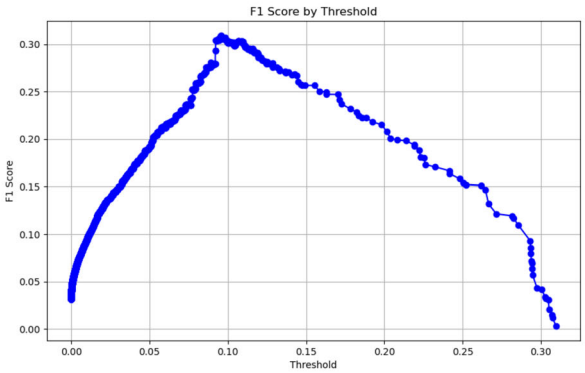

3.2.ROC-AUC曲线

为了全面评估模型在非平衡数据集上的性能，我们使用了ROC-AUC曲线。ROC-AUC曲线是接收者操作特征（ROC）曲线下的面积，可以衡量模型区分正类和负类的能力。在二分类问题中，ROC-AUC曲线的计算公式为：

$$AUC = \frac{1}{2} \times (\text{Recall}_+ - \text{Recall}_-)$$

其中，`Recall_+`和`Recall_-`分别表示正类和负类的召回率。

- 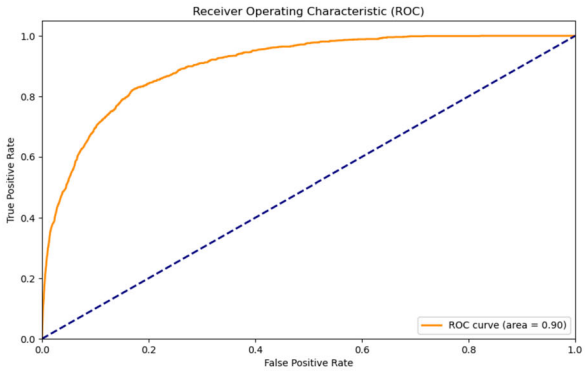

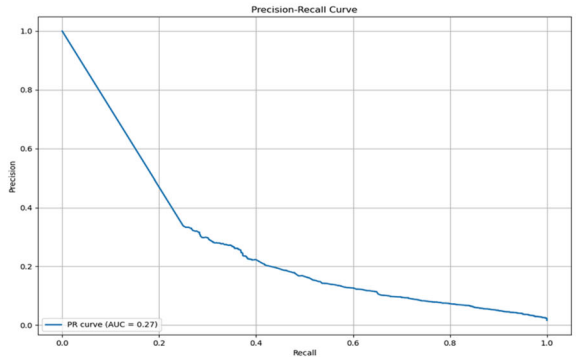

3.3.PR曲线

为了更直观地评估模型在非平衡数据集上的性能，我们使用了PR曲线。PR曲线是精确度-召回率曲线，可以显示模型在不同的召回率水平下的准确率。在二分类问题中，PR曲线的计算公式为：

$$\text{Precision}(p) = \frac{TP}{TP + FP}$$

$$\text{Recall}(r) = \frac{TP}{TP + FN}$$

其中，`TP`表示真正例数，`FP`表示假正例数，`FN`表示假反例数。

三、神经网络模型的优缺点

优点

1. **高效处理非线性关系**：
   - 神经网络能够自动从数据中学习复杂的非线性关系，这是许多传统线性模型难以实现的。
2. **自动特征提取**：
   - 深度神经网络能够自动提取数据中的重要特征，减少了对特征工程的依赖。
3. **高度灵活性**：
   - 神经网络可以用于多种类型的数据，包括图像、文本和音频等，具有很强的适应能力。
4. **可扩展性**：
   - 随着数据量的增加，神经网络模型可以通过增加层数和神经元数量来提升性能。

缺点

1. **训练时间长**：
   - 深度神经网络通常需要大量的数据和计算资源进行训练，训练时间较长。
2. **难以解释**：
   - 神经网络模型通常被视为“黑箱”，很难解释模型的内部工作原理和预测结果。
3. **依赖硬件**：
   - 训练深度神经网络需要高性能的硬件支持，如GPU或TPU，对硬件资源要求较高。