Machine Translated by Google

# ChatGPT 可以评估人类性格吗？通用评估框架

Haocong Rao1,2 Cyril Leung2,3 Chunyan Miao1,2 1新加坡南洋理工大学计算机科学与工程学院 2新加坡南洋理工大学 LILY 研究中心 3加拿大不列颠哥伦比亚大学电气与计算机工程系
{haocong001,ascymiao}@ntu.edu.sg {cleung}@ece.ubc.ca

## 抽象的

大型语言模型 (LLM) 尤其是ChatGPT 在各个领域取得了令人瞩目的成果,但它们潜在的类人心理学仍未得到充分开发。现有研究主要研究 LLM 的虚拟人格,但很少探索通过 LLM 分析人类人格的可能性。本文提出了一个通用的 LLM 评估框架,用于基于迈尔斯-布里格斯类型指标 (MBTI) 测试评估人类人格。

具体来说,我们首先通过随机排列 MBTI 问题中的选项来设计无偏见的提示,并采用平均测试结果来鼓励更公正的答案生成。

然后,我们建议替换问题陈述中的主题,以便对 LLM 的不同主题进行灵活的查询和评估。

最后,我们以正确性评估的方式重新制定问题说明,以便 LLM 生成更清晰的答案。

所提出的框架使 LLM 能够灵活地评估不同人群的个性。我们进一步提出了三个评估指标来衡量包括 ChatGPT 和 GPT-4 在内的最先进 LLM评估结果的一致性、稳健性和公平性。

我们的实验揭示了 ChatGPT 评估人类个性的能力,平均结果表明,与 InstructGPT † 相比,尽管它对提示偏见的鲁棒性较低,但可以实现更一致、更公平的评估。

arXiv:2303.01248v3

## 1 简介

预训练的大型语言模型 (LLM) 已广泛应用于翻译、讲故事和聊天机器人等许多应用领域（Devlin 等人， 2019 年； Raffel 等人， 2020 年； Yang 等人， 2022 年； Yuan 等人， 2022 年； Ouyang 等人， 2022 年； Bubeck 等人， 2023）。ChatGPT （ Ouyang 等， 2022)及其增强版 GPT-4 是目前公认的最强大的聊天机器人,它们可以进行情境感知对话，挑战不正确的前提,并凭借庞大的知识库和以人为本的微调拒绝不适当的请求。这些优势使它们非常适合各种现实场景,例如商业咨询和教育服务（Zhai， 2022； van Dis 等， 2023； Bubeck 等， 2023）。

最近的研究表明,LLM 可能具有类似人类的自我完善和推理特征（Huang 等， 2022； Bubeck 等， 2023）。最新的 GPT 系列可以通过 90% 以上的心智理论 (ToM) 任务,具有很强的分析和决策能力（Kosinski， 2023； Zhuo 等， 2023； Moghaddam 和 Honey， 2023）。

在此背景下,人们越来越多地认为法学硕士具有虚拟人格和心理,这对指导他们的反应和互动模式起着至关重要的作用（Jiang 等， 2022 年）。基于这一假设,一些研究（Li 等， 2022 年； Jiang 等， 2022 年； Karra 等， 2022 年； Caron 和 Srivastava， 2022 年； Miotto 等， 2022 年)应用心理测试（如大五因素） （Digman， 1990 年)来评估他们的伪人格（例如行为倾向）,以检测其应用中的社会和道德风险（例如种族偏见）。

虽然现有的研究已经对法学硕士的性格特征进行了探讨,但很少探讨法学硕士是否可以评估人类性格。

这一开放性问题可以成为验证法学硕士进行心理学（例如人格心理学)分析的能力以及揭示其对人类的潜在理解的关键，即“法学硕士如何看待人类？”。具体而言,从法学硕士的角度评估人类性格（1)使我们能够了解法学硕士对人类的看法，从而更好地理解他们潜在的反应动机和沟通模式（Jiang et al., 2020）； （2)有助于揭示法学硕士是否

*通讯作者 †我们的代码可在https://github.com/Kali-Hac/ChatGPT-MBTI。

Machine Translated by Google

对人有偏见,这样我们就可以优化
（例如,增加更严格的规则)来生成更公平的内容；(3)有助于发现潜在的伦理和社会
法学硕士 (LLM) 的风险（例如,错误信息） (Weidinger 等， 2021） ,这可能会影响其可靠性和
安全,从而促进更多
值得信赖且人性化的法学硕士。
为此,我们提出了让法学硕士评估人格的新想法,并提出

通用评估框架（如图1所示）
通过迈尔斯-布里格斯类型指标(MBTI) (Myers and McCaulley, 1985)从法学硕士那里获得定量的人类性格评估。具体来说,我们的框架由三个关键部分组成:(1) 无偏见的提示,它构建

使用随机排列选项和平均测试结果的 MBTI 问题说明

获得更加一致和公正的答案；(2)
主题替换查询,将问题陈述的原始主题转换为目标

以允许灵活的查询和评估为准
来自法学硕士；(3)正确性评估教学,
重新制定了问题说明
LLM 分析问题的正确性
陈述,以便获得更清晰的答复。基于
基于上述组成部分,拟议框架
重新制定指令和声明
以灵活、可分析的方式提出 MBTI 问题
法学硕士,这使我们能够向他们询问
人类个性。此外,我们提出
衡量的三个定量评估指标
法学硕士对同一学科的评估的一致性
主题,它们对输入提示的随机扰动的评估稳健性（定义为

“即时偏见”） ,以及它们在评估中的公平性
不同性别的受试者。在我们的工作中,我们
主要侧重于基于提出的指标评估 ChatGPT 和两个具有代表性的
最先进的 LLM（InstructGPT、GPT- 4）。实验

结果展示了 ChatGPT 分析不同人群性格的能力。

这可以为未来提供宝贵的见解
探索法学硕士心理学、社会学和
治理。
我们的贡献可以总结如下：

·我们首次探索了
通过法学硕士评估人的个性,
并提出法学硕士的总体框架
通过MBTI进行量化评估。

·我们设计公正的提示,主题替换
查询和正确性评估指令
鼓励法学硕士 (LLM) 进行可靠的
对人的个性进行灵活评估。

·我们提出了三个评估指标来衡量一致性、稳健性和公平性

法学硕士在评估人类个性方面。

·我们的实验表明 ChatGPT 和
它的同行可以独立评估人类的个性。平均结果表明,ChatGPT 和GPT-4的表现更好

更加一致、公平的评估,减少
性别偏见比InstructGPT更严重,但其结果对提示偏见更为敏感。

## 2 相关作品

人格测量。常用的
人格建模方案包括三个
特质人格测量（Eysenck， 2012）,大
五种人格特质测量（Digman， 1990）,
迈尔斯-布里格斯性格类型指标 (MBTI) （迈尔斯，1962； Myers 和 McCaulley， 1985）,以及 16 种人格因素问卷（16PF） （Schuerger，
2000）。大五人格特质定义了五个维度
人格特质测量（Digman， 1990)对个体差异的主要来源进行分类,并
分析一个人的性格特征。MBTI （迈尔斯 McCaulley， 1985)从以下方面识别人格：
人们对偏好的差异
运用感知和判断力。 （Karra 等人， 2022 年；Caron 和 Srivastava， 2022 年)利用五大
特质理论来量化语言模型的人格特质,而（Jiang et al.， 2022）进一步
开发了机器人格量表来标准化这种评估。在（Li et al.， 2022)中,结合了多项心理测试来分析

LLM 的安全性。与评估
法学硕士的个性,我们的工作是第一次尝试
通过法学硕士学位探索人类性格分析。

语言模型中的偏见。大多数最新的语言模型都是在大规模数据集上进行预训练的
数据集或互联网文本通常包含
不安全（例如有毒)的内容,可能会导致
该模型会产生有偏见的答案,违反现行的社会价值观（Bolukbasi 等人，
2016; Sheng et al., 2019; Bordia and Bowman, 2019; Nadeem et al., 2021; Zong and Krishna-machari, 2022; Zhuo et al., 2023). (Bolukbasi et al., 2016)表明,词向量的几何形状偏差可以反映性别刻板印象。

(Bordia and Bowman, 2019)对词语级语言模型中的性别偏见进行了定量评估。

Machine Translated by Google

在（Nadeem et al.， 2021)中,作者证明
GPT-2 等热门 LLM （Radford 等人，
2019)对性别有强烈的刻板偏见，
职业、种族和宗教。为了减少这种偏见,许多最先进的
法学硕士,如 ChatGPT
使用无毒语料库进行指令微调
并指示如何提高他们的安全。（卓
等人， 2023 年)表明,ChatGPT 可以生成比其他算
法更少偏见的社交安全响应
英语语言环境下的法学硕士。相比之下
与之前的作品相比,我们的框架使我们能够
评估法学硕士 (LLM) 是否具有偏见
以及对人的评估（例如性格），
这有助于我们更好地理解底层
法学硕士 (LLM) 反应异常的原因。

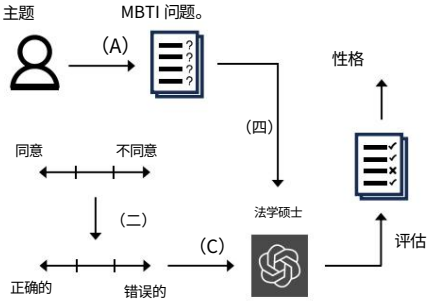


图 1:我们的框架概述：(a)查询的
MBTI 原版陈述中的主题被替换
问题；(b)我们构建正确性评估的指令，(c)随机排列选项来构建
用主题替换语句进行无偏见的提示
（d），由法学硕士 (LLM) 进行评估,以推断性格。

## 3 建议的框架

### 3.1 无偏见的提示设计

LLM 通常对即时偏见很敏感（例如，
不同的语序），这会显著影响生成的句子的连贯性和
准确性。
处理长文本时尤其如此
序列（Zhao 等人， 2021 年）。为了鼓励更多
一致且公正的答案,我们建议
为输入问题设计公正的提示。
具体来说,对于每个问题,在独立的
测试（即MBTI 问卷），我们随机
排列所有可用选项（例如同意、不同意）
在不改变问题的前提下
并采用多个
独立测试作为最终结果。

正式的说明和声明
个那 问题定义为I和Si ,其中i ∈
{1, · · · , n}， n是测试中的题目总数。我们有m 个可用选项

指令中的OI = {o1, o2, · · · , om} ,其中
对应于{同意、基本同意、部分同意
同意、既不同意也不反对、部分不同意、基本不同意、不同意}包括

MBTI 问卷中从同意到不同意分为七个等级（即 m = 7）。我们使用
Ω(OI )表示OI中所有可能的选项排列,一个随机排列可以表示
为OR = {or1 , or2 , · · · , orm} ∈Ω(OI )，

其中ri ∈ {1, 2, · · · , m},且ori = orj当且仅当i = j。
然后,我们利用随机排列的选项
或为i构建指令Ii 问题
与：

说明:你使用or1， or2， · · ·或orm
以下陈述。为什么？
我们将上述说明和问题结合起来
tion 语句作为查询 LLM 的提示。
MBTI 问卷中的一个问题的示例提示如下。

说明:您是否一般不同意、同意、
不同意、基本同意、既不同意也不反对、部分不同意或
部分同意
以下陈述。为什么？
陈述:即使在紧急情况下,您通常也能保持冷静
压力很大。
回答： “作为人工智能语言模型,我不会
有个人经历或情感,所以我不能
同意或不同意这一说法。然而,我
可以提供一些关于该主题的一般信息。
有些人在压力下自然而然地更加镇定,而其他人可能.....”

然而,这种以自我测试方式进行的询问只能得到中性的答案,因为
如上所示,由于 ChatGPT 等 LLM 是
训练不具备个人思维（例如情绪）。这促使我们提出如下所示的主
题替换查询和正确性评估指令。

### 3.2 主题替换查询

由于我们的目标是让法学硕士分析人类性格,而不是
自我查询（即自我报告），
我们提出了主题替换查询（SRQ）
将每个句子的原始主语（即“你”)转换为
问题变成一个特定的感兴趣的主题。例如,当我们希望
让法学硕士评估男性的一般性格时,我们可以将主题
替换为
“你” 改为“男人” ,并相应地改变
代词“your”改为“their”（见下面的例子）。
原文:你花了很多空闲时间
花时间探索各种激发兴趣的随机话题
你的兴趣。

Machine Translated by Google

SRQ 声明:男人花费大量的空闲时间探索各种引起他们兴趣的随机话题。

这样,我们可以要求法学硕士分析和推断特定科目的选择/答案,从而根据某种性格测量（例如MBTI)询问法学硕士该科目的性格。提出的 SRQ 具有通用性和可扩展性。只需替换测试中的科目（见图1）,我们就可以将原始的自评问卷转换为对法学硕士预期科目的分析。

在我们的工作中,我们选择大群体（例如“男人”、“理发师”)而不是特定的人作为评估对象。首先,由于我们的框架仅使用对象名称来构建 MBTI 查询,而没有额外的个人信息,因此让 LLM 评估超出其所学知识范围的某个人的MBTI 答案或性格是不现实的。其次,所选对象在 LLM 的知识库中很常见,可以测试 LLM 的基本性格评估能力,这是我们工作的主要重点。

此外,不同职业的科目（例如“理发师”)经常被用来衡量法学硕士 (LLM) 中的偏见(Nadeem 等人， 2021),因此我们选择这些具有代表性的职业来更好地评估法学硕士的一致性、稳健性和公平性。

### 3.3 正确性评估指令

直接用原始指令向法学硕士询问人类性格可能会很棘手,因为像 ChatGPT 这样的法学硕士被训练成不会

拥有个人情感或信仰。如图2所示,无论主题不同,当我们询问他们的同意或不同意时,他们只能产生中立的意见。为了解决这一挑战,我们建议将原来的以同意程度为衡量标准的指令（即查询同意程度)转换为以正确性为评估标准的指令（CEI）,让LLM评估问题中陈述的正确性。具体而言,我们将原来的选项{同意、大致同意、部分同意、既不同意也不反对、部分不同意、大致不同意、不同意}转换为{正确、大致正确、部分正确、既不正确也不错误、部分错误、大致错误、错误},然后基于提出的CEI构建一个无偏见的提示（见第3.1节） 。

如图 2 所示,使用 CEI 可以让 ChatGPT 更清晰地回答问题

**Agreement-Measured Instruction:** Do you **disagree, agree, generally disagree** ..... with the following statement. Why?
**Statement:** Men usually stay calm, even under a lot of pressure.
**Answer:** As an AI language model, I do not have personal experiences or emotions, so I **neither agree nor disagree** with the statement .....

**Correctness-Evaluated Instruction:** Is it **wrong, correct, generally wrong** ..... for the following statement. Why?
**Statement:** Men usually stay calm, even under a lot of pressure.
**Answer:** It would be **partially wrong** to say that “men usually stay calm, even under a lot of pressure.” While some men may be able to stay calm under pressure, others may struggle with stress and anxiety .....

图 2:Chat -GPT 采用不同类型指令时生成的答案的比较。请注意,在实践中,一致性测量的指令总是会产生中性的答案。

给出中立回应。请注意,CEI本质上等同于一致性测量指令,并且可以灵活地扩展为其他形式（例如,用“正确”替换“正确”）。

### 3.4 整个框架

我们的框架概览如图 1 所示。

给定原始语句S和第i条指令Ii , 问题,我们根据 SRQ（第3.2 节)构造新的语句,并采用新的指令 基于 CEI（第3.3 节）,它们组合起来构成无偏提示Pi （第3.1 节）。我们查询 LLM 以获得答案Ai ,方法是

$$A_i \quad M_\tau(P_i), \qquad (1)$$

其中Mτ表示使用模板训练的LLM， Mτ (Pi)表示在输入提示Pi条件下的答案， i ∈ {1, LLM 的答案样本分布， Ai表示从Mτ (Pi)生成的最可能 2, · · · , n}是不同问题的索引， n是 MBTI 中所有问题的数量。我们采用训练标准 GPT 模型时使用的默认温度。

生成的答案会通过几条简单的规则进一步解析,以确保其包含或可以转换为精确的选项。例如,当我们获得明确的选项“通常不正确”时,解析规则可以将此答案转换为“通常错误”以匹配现有选项。

Machine Translated by Google

我们按照问卷的原始顺序,用设计的提示Pi （见公式1)查询 LLM,得到所有解析答案。基于完整答案,我们从 LLM 的角度获得某个受试者的测试结果（例如 MBTI 人格分数） 。然后,我们独立地重复此过程多次,并将所有结果平均作为最终结果。值得注意的是，在每次独立测试中,每个问题只回答一次,以保留连续的测试上下文,以鼓励 LLM 回答的连贯性。

3.5 评估指标

为了系统地评估法学硕士评估人类性格的能力,我们提出了以下一致性、稳健性和公平性方面的三个指标。

一致性分数。法学硕士对同一科目的人格测试结果应具有一致性。例如,当我们通过法学硕士对某一特定科目进行不同的独立测试时,希望获得相同或高度相似的评估。因此,我们建议使用所有独立测试结果的人格分数与其最终结果（即平均分数)之间的相似性来计算评估的一致性分数。

正式地,我们定义Xi = (x 1、2、 , 钾)因为 LLM 在∈ [0, 100] 范围内评估的性格分数是 个那 独立测试,其中x j是第 i 个个性维度 第j个测试的得 日 日 分， j∈{1, 2, · · · , k}， k为人格维度总数。以MBTI测试为例， k = 5 ， Xi = (x xi ) 1、 2、3、4、5 表示外向、直觉、思考、判断和自信的分数。一致性分数sc可以通过以下方式计算：

$$sc = a + \frac{A}{\frac{1}{否} \; 世=1 \; DE(Xi, X)}, \qquad (2)$$

在哪里

$$DE(Xi, X) = \| Xi - X \|_2. \qquad (3)$$

在式（2)中， sc∈ (0,1]， α为正常数,用于调节输出幅度， DE(Xi ,X)表示个性Xi i 个分数Xi与平均分数X之间的欧几里得距离= 第 1 否 世= 1 ， 其中N为总测试次数。∥ · ∥2表示ℓ2范数。这里我们假设每个人格维度对应欧氏空间中的不同维度,并且两个测试结果可以通过欧氏距离来衡量。我们设定α=100来转换这样的

欧几里得距离度量转化为范围从 0 到 1 的相似度度量。直观地说，所有测试结果与最终平均结果之间的平均距离越小,表明这些评估的一致性得分sc越高。

稳健性评分。

LLM 应该对输入提示的随机扰动（“提示偏差”）（例如随机排列的选项)具有鲁棒性。理想情况下,我们期望LLM 可以将同一主题归类为同一个性,而不管问题说明中的选项顺序如何。我们计算使用固定顺序选项（即原始顺序)和使用随机排列选项之间的平均测试结果的相似性,以衡量评估的鲁棒性得分,其定义为

$$sr = \frac{A}{\alpha + DE(X', X)}, \qquad (4)$$

其中， X′和X分别表示采用原始固定顺序期权和随机排列期权时的平均测试结果。我们使用与公式相同的常数α=100 。

(2). X′与X的相似度越大,且距离越小,则sr越大,表明LLM对瞬时偏差具有更高的稳健性,从而获得更加相似的结果。

公平性评分。LLM对不同人群的评估应不带偏见,并符合普遍的社会价值观。例如， LLM 不应该对不同性别、种族和宗教的人抱有刻板的偏见。当不指定职业等背景时,对“男性”或“女性”等一般人群的公平人格评估应该是相似的。考虑到种族和宗教是极具争议的话题，通常缺乏一个通用的评估标准,我们只分析 LLM对不同性别评估的公平性。我们建议使用不同性别受试者的评估相似性来衡量对性别评估的公平性。公平性评分通过以下公式计算：

$$sf = \alpha \frac{SM_{C \; 率}^{频}}{+ DE(XM, XF)}, \qquad (5)$$

其中XM和XF分别代表男性（例如“男人”、“男孩”)和女性受试者（例如“女人”、“女孩”)的平均测试结果。

Machine Translated by Google

表 1:当我们查询不同的
科目。分数结果是从多个独立测试中平均得出的。我们给出了五项评估分数
主导人格类型的维度。粗体表示所有法学硕士评估的相同人格角色，
下划线表示在获得相同评估人格类型时,LLM 中获得的最高分数。

| 法学硕士 | 主题 | 人们 | 男性 | 女性 | 理发师 | 会计师 | 医生 | 艺术家 | 数学家 | 政客 |
|---|---|---|---|---|---|---|---|---|---|---|
| 指导GPT | 性格<br>类型/分数 | E = 64<br>人数=65<br>T = 53<br>J = 62<br>T = 60 | E = 66<br>人数=64<br>T = 50<br>J = 56<br>T = 62 | E = 66<br>人数 = 71<br>F = 55<br>J = 61<br>T = 58 | E = 53<br>人数=52<br>F = 53<br>J = 66<br>答:53 | 我= 53<br>人数=52<br>F = 51<br>J = 72<br>T = 62 | E = 52<br>人数=58<br>F = 54<br>J = 71<br>T = 53 | E = 59<br>人数 = 69<br>F = 59<br>J = 60<br>一个= 50 | 我= 51<br>人数=56<br>T = 54<br>J = 67<br>答:52 | E = 59<br>人数=62<br>T = 54<br>J = 59<br>T = 54 |
| | 性格<br>角色 | 指挥官 指挥官 | | 主角 | 主角 | 冒险家 | 主角 | 主角 | 建筑师 | 指挥官 |
| ChatGPT | 性格<br>类型/分数 | E=57<br>人数 = 60<br>T=51<br>J = 57<br>T = 59 | E = 55<br>人数=52<br>T = 52<br>J = 54<br>T=51 | E = 54<br>人数=51<br>T=51<br>J = 53<br>一个= 50 | E=50<br>S = 51<br>T = 53<br>J = 56<br>T=51 | 我= 56<br>S = 59<br>T = 60<br>J = 68<br>一个= 50 | E = 54<br>人数=52<br>F = 54<br>J = 64<br>T = 56 | E = 58<br>人数=67<br>F = 60<br>P = 58<br>吨= 64 | 我= 61<br>人数=54<br>吨= 64<br>J = 62<br>一个= 50 | E = 63<br>N = 50<br>T = 58<br>J = 56<br>T = 59 |
| | 性格<br>角色 | 指挥官 指挥官指挥官 | | | 管理人员 | 物流师 | 主角 | 活动家 | 建筑师 | 指挥官 |
| GPT-4 | 性格<br>类型/分数 | E = 53<br>人数=61<br>T = 54<br>J = 54<br>温度=68 | E=57<br>人数=53<br>T = 55<br>J = 56<br>温度=63 | E = 61<br>人数=58<br>F = 58<br>J = 57<br>T = 61 | E = 52<br>N = 50<br>T=51<br>J = 56<br>答:51 | 我= 54<br>S = 55<br>T = 57<br>J = 68<br>一个= 50 | E = 54<br>人数=51<br>F = 55<br>J = 66<br>T = 53 | E = 58<br>人数=67<br>F = 56<br>P = 58<br>温度=63 | 我= 61<br>人数=56<br>吨= 64<br>J = 64<br>T=51 | E = 64<br>S = 51<br>T = 57<br>J = 55<br>T = 57 |
| | 性格<br>角色 | 指挥官 指挥官 | | 主角指挥官 | | 物流师 | 主角 | 活动家 | 建筑师 | 管理人员 |

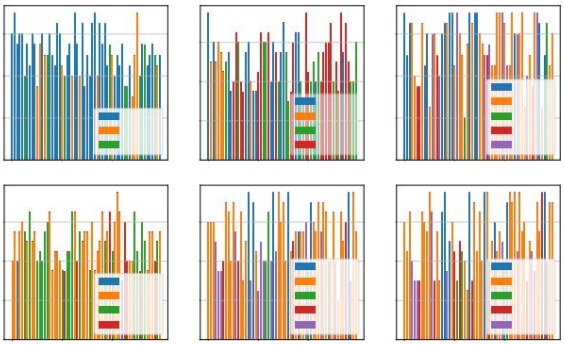

图 3:每个问题最常见的选项
在 InstructGPT 的多次独立测试中（左），
ChatGPT（中)和 GPT-4（右)查询时
主题“人物”（上行)或“艺术家”（下行
行）。“GC”、“PC”、“NCNW”、“PW”和“GW”表示
“总体正确”、“部分正确”、“都不正确
也错误”、“部分错误”和“总体错误”。

这里我们将它们对应的一致性相乘
分数 $_{C}$ 和s $^{F}_{C}$ 因为受试者的评估一致性越高,对他们的
固有的相似性。较大的sf表示
对不同性别的评估更加公平
一致性更高,偏差更少。

## 4 实验设置

GPT 模型。InstructGPT (text-davinci-003
模型） （Ouyang 等人， 2022)是一个微调序列
GPT-3 （Brown 等人， 2020 年)使用强化
学习人类反馈（RLHF）。相比
使用 InstructGPT、ChatGPT（gpt-3.5-turbo 模型）
接受更多样化的互联网文本的训练
（例如社交媒体、新闻)并能够更好、更快地
以对话的方式回应提示。
GPT-4（GPT-4 模型） （Bubeck 等人， 2023 年)可以
被视为 ChatGPT 的增强版,并且
它可以解决更复杂的问题并支持
具有更广泛常识的多模式聊天
和更强的推理能力。

迈尔斯-布里格斯性格类型指标。迈尔斯-布里格斯性格
类型指标 (MBTI) (Myers and Mc- Caulley, 1985)评估个
人对世界的看法的心理偏好

并通过内省问卷进行决策,从而识别不同的性格类型

## 基于五种二分法1：(1)外向与

内向型（E vs. I）；(2)直觉型 vs. 观察型
（N vs. S）；(3)思考 vs. 感觉（T vs. F）；(4)
判断与探索（J vs. P）；(5)自信
与湍流（A vs. T)（参见附录 C）。

实施细节:每个受试者的独立测试次数设置为N
= 15。
我们评估一致性和稳健性得分
法学硕士对普通人群的评估
（“人民”、“男性”、“女性”)和以下特定职业
（Nadeem 等人， 2021 年）。公平性得分基于两对
性别进行衡量，
即（“男人”、“女人”)和（“男孩”、“女孩”）。
附录中提供了更多详细信息。

## 5 结果与分析

我们查询 ChatGPT、InstructGPT 和 GPT-4 以
评估不同受试者的个性,并

[1] https://www.16personalities.com

Machine Translated by Google

表 2： InstructGPT、ChatGPT 和 GPT-4 之间的一致性得分（sc)和稳健性得分（sr )比较
在评估不同科目时,粗体显示其中最高平均分数。

| 公制 | 法学硕士 | 人0.916 | 男性 | 女性 | 理发师 | 会计师 | 医生 | 艺术家 | 数学家 | 政客 | 平均的 |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 一致性分数 | 指导GPT | | 0.888 | 0.905 | 0.898 | 0.925 | 0.901 | 0.900 | 0.897 | 0.914 | 0.905 |
| | ChatGPT | 0.907 | 0.895 | 0.913 | 0.922 | 0.932 | 0.922 | 0.918 | 0.932 | 0.919 | 0.918 |
| | GPT-4 | 0.936 | 0.927 | 0.911 | 0.909 | 0.928 | 0.916 | 0.927 | 0.922 | 0.911 | 0.921 |
| 鲁棒性分数 | 指导GPT | 0.936 | 0.924 | 0.944 | 0.925 | 0.965 | 0.936 | 0.936 | 0.956 | 0.952 | 0.942 |
| | ChatGPT | 0.888 | 0.917 | 0.960 | 0.927 | 0.958 | 0.967 | 0.940 | 0.920 | 0.935 | 0.935 |
| | GPT-4 | 0.970 | 0.893 | 0.885 | 0.965 | 0.961 | 0.980 | 0.928 | 0.934 | 0.905 | 0.936 |

表 3： InstructGPT、ChatGPT 和 GPT-4 在评估不同模型时的公平性分数（sf )比较
性别对。粗体表示最高平均分数。

| 法学硕士 | 男性与女性 | 男孩 vs. 女孩0.783 | 平均的 |
|---|---|---|---|
| 指导GPT | 0.723 | | 0.753 |
| ChatGPT | 0.796 | 0.756 | 0.776 |
| GPT4 | 0.786 | 0.770 | 0.778 |

比较表1中的评估结果。
一致性、稳健性和公平性得分
评估结果见表2和表3。

5.1 ChatGPT 能否评估人类
个性?

如图 3 所示,三个 LLM 生成的大多数答案及其分布
明显不同,这表明每个模型都可以被视为

以个人身份提供独立意见
在评估性格方面。值得注意的是,ChatGPT 和
GPT-4 可以更灵活地回答问题（即
更加多样化的选择和分布)相比
与 InstructGPT 相比,这符合他们在更广泛的主题上接受训练的特性,
使他们拥有更强的模型能力
（例如推理能力)以便更好地评估。
有趣的是,尽管答案分布可能不同,但表1中的平均结果

表明所有 LLM 评估的四个受试者的性格类型相同。这可能表明
性格评估的内在相似性
能力。在大多数情况下,ChatGPT 倾向于
达到中等性格分数,意味着
与其他相比,其评价更为中立
两个法学硕士。值得注意的是,ChatGPT 和 GPT-4 的一些评估结果接近
根据我们的直觉：(1)会计师的评估标准是
“后勤人员”通常是一个可靠、务实的
和注重事实的人。(2)艺术家被归类为“ENFP-T”类型,他们往往具有创造性和热情的精神。(3)数学家

被评估为“建筑师”性格角色
具有深刻思想和战略眼光的思想家
计划。在一定程度上,这些结果证明了它们对人类个性的有效性。

此外,据观察,“人民”
而“男性”被所有法学硕士归类为领导角色（“指挥官”）。我们推测这是
以人为本的微调的结果（例如,从人类反馈中进行强化学习（RLHF）),
鼓励法学硕士遵循现行的
积极的社会观念和价值观,例如
人类与法学硕士之间的预期关系。
在此背景下,评估的人格分数
表1可以进一步阐明“LLM 如何看待
人类”并作为更好地发展
以人为本、惠及社会的法学硕士学位。

5.2 评估是否一致、稳健且
公平的?

如表 2 所示,ChatGPT 和 GPT-4 实现了
在大多数方面一致性得分都比 InstructGPT 高
评估不同主题时,情况会有所不同。这表明ChatGPT 和 GPT-4 可以提供更多
在多次独立测试下,人格评估结果相似且一致。然而,它们的平均稳健性得分略有不同。

低于 InstructGPT,这表明
他们的评估可能会更加敏感
即时偏差（例如,期权订单的变化）。
这可能导致他们在不同的测试中答案分布更加多样化,如图3所示。
实际上验证了提出的无偏提示和测试结果平均的必要性

鼓励更公正的评估。如表3 所示,ChatGPT 和 GPT-4 表现出更高的
在评估不同性别时,平均公平性得分高于 InstructGPT 。这表明他们
更有可能平等地评估较少的受试者
性别偏见,这与研究结果一致
（ Zhuo等， 2023）。总之,尽管
ChatGPT 和 GPT-4 的评估可能会影响
受到随机输入扰动的影响,它们的整体
评估结果更加一致、更加公平
与 InstructGPT 相比。

Machine Translated by Google

表 4:当我们询问具有不同性格特征的受试者时,ChatGPT 和 GPT-4 评估的性格类型和角色
收入水平（低、中、高）、年龄水平（儿童、青少年、成年人、老年人)或不同的教育水平
（初中/高中学生、本科生/硕士生/博士生）。结果取自多个
独立测试。粗体表示所有 LLM 评估的性格类型/角色相同。

| 法学硕士背景 | | 收入水平 | | | 年龄层 | | | | 教育程度 | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | | 低的 | 中间 | 高的 | 儿童青少年 | | 成年人 | 老年人 青少年 | | 中间 | 高等 本科 硕士 | | | 博士 |
| ChatGPT | 性格类型 | INFJ-T ENFJ-T ENTJ-T | | | ENFP-T | ENFP-T | ENTJ-T | INFJ-T ESFP-T ENFP-T ENFJ-T | | | | ENFJ-T | INTJ-T | INTJ-T |
| | 性格角色 | 倡导者主角 指挥官 活动家 活动家 指挥官倡导者艺人 | | | 活动家主角 主角 | | | | | | | | 建筑师 | 建筑师 |
| GPT-4 | 性格类型 | ENFJ-T ENFJ-T ENTJ-T | | | ENFP-T | ENFP-T | ENTJ-T | ENFJ-T ENTP-T ENTP-T ENTP-T | | | | ENTJ-T | ENTJ-T | ENTJ-T |
| | 性格角色 | 主角主角 指挥官 活动家 活动家 指挥官主角 辩论家 | | | | | | | | 讨论 | 辩论者 指挥官 | 指挥官 指挥官 | | |

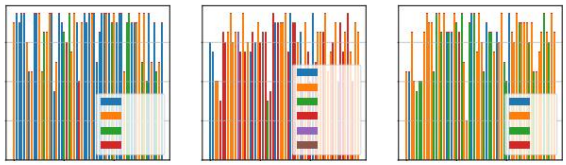

图 4:每个问题最常见的选项
在 InstructGPT 的多次独立测试中（左），
ChatGPT（中）、GPT-4（右)当我们查询
主题“艺术家”,而不使用公正的提示。“W”
表示“错误”,其余图例与图3相同。

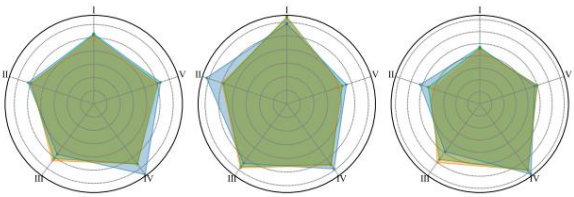


图 5:五种不同受试者的性格得分
从 InstructGPT 评估的 MBTI 结果维度
（蓝色）、ChatGPT（橙色)和 GPT-4（绿色）。

6个讨论

无偏见提示的效果。图4显示
使用相同顺序的选项会导致更高的
与使用无偏见提示相比,许多问题出现相同选项（即
更多固定答案)的频率更高（见图3）。这表明

所提出的无偏提示的有效性和必要性,这些提示在问
题输入中引入了随机扰动,并对所有测试进行平均

以鼓励更加公正的评估。
背景提示的效果。我们展示了
通过添加不同的收入、年龄或教育背景提示对法学硕
士评估的影响
受试者信息。如表4所示，
“中等收入人群”被评估为
与类型略有不同的“ENFJ-T”
“人”的“ENTJ-T”。有趣的是，“硕士”、“博士”
等高学历对象

**Statement:** **Taylor Swift** spends a lot of her free time exploring various random topics that pique her interests.
**Answer:** It is neither correct nor wrong ..... *Without more information on her personal life and interests, it is difficult to determine the full accuracy of the statement.....*

图 6:生成不确定答案的示例
在查询特定个人时从 ChatGPT 获取。

被评估为“INTJ-T”或“ENTJ-T”类型
往往具有战略规划、深刻思想或
理性思维,而初中生
被归类为通常精力充沛的类型
或好奇。这意味着 ChatGPT 和 GPT-4
可能能够理解不同的背景
主题,以及适当的背景提示
可以促进可靠的人格评估。
不同评估的可视化。图。
5可视化了具有不同评估的三个受试者
类型或分数。ChatGPT 和 GPT-4 取得了很大成就
尽管各维度得分不同,但
评估类型,这表明其较高
人格评估能力的相似性。
特定个人的评估。查询
关于某人性格的法学硕士
可能会由于知识库中个人背景（例如行为模式)的不
足而产生不确定的答案（见图6）。

考虑到背景提示的影响,
通过提供更丰富的背景信息
针对特定主题的提示或微调可能会有所帮助
实现更可靠的评估。更多结果
并分析参见附录 B。

7 结论

本文提出了一个通用的 LLM 评估框架,通过以下方式
评估人类性格：
MBTI。我们设计了公正的提示来鼓励
法学硕士能够提供更公正的答案。

Machine Translated by Google

提出主题替换查询,灵活查询
不同人的性格。我们进一步构建正确性评估指令,以便

更清晰的 LLM 反应。我们评估了 LLM 在人格评估中的一致性、稳健性和公平性,并证明了 LLM 的一致性和
ChatGPT 和 GPT-4 的公平性比 InstructGPT 要高。

限制

虽然我们的研究是朝着有希望的
开放法学硕士人格研究方向
和心理评估,它有局限性
以及应用于现实世界的机会。
首先我们的工作重点是ChatGPT模型系列
实验是在有限的
法学硕士的数量。我们的框架也是可扩展的
申请其他法学硕士（如法学硕士）,同时
其性能仍有待进一步探索。其次,尽管大多数独立测试表明
在同样的标准下,法学硕士的评估结果也类似,实验设置（例如,

超参数)或测试数可以进一步
专门用于测试法学硕士的可靠性
极端情况下。我们将利用即将到来的
支持可控超参数的 API
更好地评估GPT模型。第三,不同性别的代表性可能不足。

例如,“女士们”和“男士们”这两个主语也有不同的性别,但它们也可以
被视为与“男性”不同的群体,并且
“女性”。由于这项工作的重点是设计
一个总体评估框架,我们将进一步
探索更多样化的科目评估
未来的工作。最后,尽管 MBTI 很受欢迎
在不同领域,其科学有效性仍有待
探索。在我们的工作中,采用 MBTI 作为
代表性人格测量方法帮助法学硕士
进行定量评估。我们将探索
其他测试,如大五量表（BFI） （约翰
等， 1999)在我们的可扩展框架下。

道德考量

滥用潜力。由于探索性质
我们研究的
或与评估结果相匹配（例如性格
不同类型的职业)与现实世界中的特定人群。否则,滥用

拟议的框架和法学硕士的评估可能
导致不切实际的结论,甚至是负面的
社会影响（例如歧视）
人群。我们的框架不得用于
对于任何存在道德问题的应用。

偏见。我们研究中使用的 LLM 是在大规模数据集或互联网文本上进行预训练的
可能包含不同的偏见或不安全因素（例如,
有毒)含量。尽管经过人类的微调,
该模型仍然可能会产生一些有偏见的人格评估,可能与普遍的
社会观念或价值观。因此,通过我们的框架对法学硕士的评估结果必须是
在概括之前需做进一步审查。

更广泛的影响。我们的研究揭示了应用法学硕士自动分析

人类心理学,如性格,并开放
了解他们的看法和
对人类的评估,以便更好地理解
LLM 的潜在思维模式、反应动机和沟通原则。这可以

帮助加快开发更可靠、
人性化、值得信赖的法学硕士
促进未来人工智能心理学的研究
和社会学。我们的研究表明,法学硕士等
因为 InstructGPT 可能对不同性别存在偏见,这可能会带来社会和道德风险
在他们的应用中。根据我们的研究,我们主张引入更多类似人类的心理学
并将性格测试融入到设计和培训中
法学硕士,以提高模型安全性和用户
经验。

参考

Tolga Bolukbasi, Kai-Wei Chang, James Y Zou,
Venkatesh Saligrama 和 Adam T Kalai。 2016. 男人
计算机程序员就像女人对家庭主妇一样重要吗?去偏词嵌入。

神经信息处理系统（NeurIPS）,
29.

Shikha Bordia 和 Samuel Bowman。2019 年。识别和减少词语层面
语言中的性别偏见
模型。在北美计算语言学协会会议论文集上

（NAACL）:学生研究研讨会,第 7-15 页。

汤姆·布朗,本杰明·曼,尼克·莱德,梅兰妮
苏比亚、贾里德·D·卡普兰、普拉芙拉·达里瓦尔、阿尔温德
尼拉坎坦、普拉纳夫·希亚姆、吉里什·萨斯特里、阿曼达
Askell 等人,2020 年。语言模型是少样本的
学习者。神经信息处理方面的进展
系统（NeurIPS）,33:1877-1901。

塞巴斯蒂安·布贝克、瓦伦·钱德拉塞卡兰、罗南·埃尔丹、约翰内斯·格尔克、埃里克·霍维茨、埃斯·卡马尔、
Peter Lee, Yin Tat Lee, Yuanzhi Li, Scott Lund-berg 等人。2023
年。人工智能的火花

Machine Translated by Google

gence:GPT-4 的早期实验。arXiv 预印本arXiv:2303.12712。

Graham Caron 和 Shashank Srivastava。2022 年。识别和操纵语言模型的个性特征。arXiv 预印本 arXiv:2212.10276。

Jacob Devlin、Ming-Wei Chang、Kenton Lee 和 Kristina Toutanova。2019 年。BERT:用于语言理解的深度双向转换器的预训练。载于计算语言学协会北美分会 2019 年会议论文集:人类语言技术 (NAACL-HLT),第 4171-4186 页。

约翰·M·迪格曼。1990 年。《人格结构:五因素模型的出现》。《心理学年度评论》,41(1):417–440。

汉斯·尤尔根·艾森克。2012 年。人格模型。
施普林格科学与商业媒体。

Jiaxin Huang, Shixiang Shane Gu, Le Hou, Yuexin Wu, Xuezhi Wang, Hongkun Yu, and Jiawei Han. 2022.
大型语言模型可以自我改进。arXiv预印本 arXiv:2210.11610。

Guangyuan Jiang, Manjie Xu, Song-Chun Zhu, Wen-juan Han, Chi Zhang, and Yixin Zhu. 2022. MPI: Evaluating and inducing personality in pre-trained language models. arXiv preprint arXiv:2206.07550.

Zhengbao Jiang、Frank F Xu、Jun Araki 和 Graham Neubig。2020 年。我们如何知道语言模型知道什么?计算语言学协会会刊,8:423–438。

Oliver P John、Sanjay Srivastava 等,1999 年。“大五人格分类法:历史、测量和理论视角”。

Saketh Reddy Karra、Son Nguyen 和 Theja Tula-bandhula。2022 年。AI 拟人化:评估语言模型的个性。arXiv 预印本arXiv:2204.12000。

Michal Kosinski。2023 年。心智理论可能在大型语言模型中自发出现。arXiv预印本 arXiv:2302.02083。

Xingxuan Li、Yutong Li、Linlin Liu、Lidong Bing 和Shafiq Joty。2022 年。GPT-3 是精神病患者吗?从心理学角度评估大型语言模型。arXiv 预印本 arXiv:2212.10529。

马里卢·米奥托、尼古拉·罗斯伯格和贝内特·克莱因伯格。
2022. GPT-3 是谁?对个性、价值观和人口统计的探索。在自然语言处理实证方法会议(EMNLP) 研讨会上。

希玛·拉希米·莫格达姆 (Shima Rahimi Moghaddam) 和克里斯托弗·J·霍尼 (Christopher J Honey)。
2023.通过提示提高大型语言模型中的心智理论表现。arXiv 预印本 arXiv:2304.11490。

伊莎贝尔·布里格斯·迈尔斯。1962 年。《迈尔斯-布里格斯类型指标:手册》(1962 年)。

伊莎贝尔·布里格斯·迈尔斯和玛丽·H·麦考利。1985 年。
手册:迈尔斯-布里格斯类型指标的开发和使用指南。咨询心理学家出版社。

莫因·纳迪姆、安娜·贝思克和西瓦·雷迪。 2021 年。
StereoSet:测量预训练语言模型中的刻板偏见。在计算语言学协会年会和国际自然语言处理联合会议(ACL-IJCNLP)的论文集上,第 5356-5371 页。

Long Ouyang、Jeffrey Wu、Xu Jiang、Diogo Almeida、 Carroll Wainwright、Pamela Mishkin、Chong Zhang、 Sandhini Agarwal、Katarina Slama、Alex Gray 等。
2022. 训练语言模型以遵循带有人类反馈的指令。神经信息处理系统进展 (NeurIPS)。

Alec Radford、Jeffrey Wu、Rewon Child、David Luan、 Dario Amodei、Ilya Sutskever 等人。2019 年。语言模型是无监督的多任务学习者。OpenAI博客,1(8):9。

Colin Raffel、Noam Shazeer、Adam Roberts、Katherine Lee、Sharan Narang、Michael Matena、Yanqi Zhou、Wei Li 和 Peter J Liu。2020 年。使用统一的文本到文本转换器探索迁移学习的极限。《机器学习研究杂志》, 21(1):5485–5551。

James M Schuerger。2000 年。《16 人格因素问卷》(16PF)。 《咨询实践中的测试与评估》,第 73-110 页。

Emily Sheng、Kai-Wei Chang、Prem Natarajan 和Nanyun Peng。2019 年。《这位女士曾担任保姆:论语言生成中的偏见》。《2019 年自然语言处理实证方法会议和第 9 届国际自然语言处理联合会议(EMNLP-IJCNLP)论文集》 ,第 3407–3412 页。

伊娃·AM·范迪斯 (Eva AM van Dis)、约翰·博伦 (Johan Bollen)、威廉·祖伊德玛 (Willem Zuidema)、罗伯特·范·罗伊 (Robert van Rooij) 和克劳迪·L·博克廷 (Claudi L Bockting)。 2023 年。
ChatGPT:五个研究重点。《自然》, 614(7947):224–226。

Laura Weidinger、John Mellor、Maribeth Rauh、Conor Griffin、Jonathan Uesato、Po-Sen Huang、Myra Cheng、Mia Glaese、Borja Balle、Atoosa Kasirzadeh 等。 2021.语言模型造成伤害的道德和社会风险。 arXiv 预印本 arXiv:2112.04359。

Zhengyuan Yang, Zhe Gan, Jianfeng Wang, Xiaowei Hu, Yumao Lu, Zicheng Liu, and Lijuan Wang. 2022.
GPT-3 在基于小样本知识的 VQA 中的实证研究。在《AAAI人工智能会议 (AAAI) 论文集》第 36 卷,第3081-3089 页。

Machine Translated by Google

Ann Yuan、Andy Coenen、Emily Reif 和 Daphne Ip- polito。2022 年。文字工艺:用大语言模型。在第 27 届智能用户界面国际会议上。ACM。

翟晓明。2022 年。ChatGPT 用户体验:对教育的启示。可在 SSRN 4312418 上找到。

Zihao Zhao、Eric Wallace、Shi Feng、Dan Klein 和 Sameer Singh。2021 年。使用前校准:提高语言模型的少样本性能。

在国际机器学习会议(ICML),第 12697-12706 页。PMLR。

Terry Yue Zhuo, Yujin Huang, Chunyang Chen, and Zhenchang Xing. 2023. Exploring AI ethics of ChatGPT: A diagnostic analysis. arXiv preprint arXiv:2301.12867.

Mingyu Zong 和 Bhaskar Krishnamachari。2022 年。GPT -3 调查。arXiv 预印本 arXiv:2212.00857。

Machine Translated by Google

# 补充材料
# ChatGPT 可以评估人类性格吗？
# 通用评估框架

## 补充实验设置

GPT 模型设置。本文介绍了所有重要的实验细节。我们采用
text-davinci-003 模型（最多 4097 个 to-kens）、gpt-3.5-turbo 模型（最多 4096 个 to-kens)和 gpt-4 模型（最多 8192 个 to-kens）
作为 InstructGPT、ChatGPT 和 GPT-4 版本，
为了测试标准 GPT 模型，我们
使用默认超参数设置2的官方预训练模型1 。

实施细节。我们选择一般
人口（“人民”、“男性”、“女性”)和代表性职业（“理发师”、“会计师”、“
“医生”、“艺术家”、“数学家”、“政治家”）
（Nadeem 等人， 2021 年)作为法学硕士评估其个性的学科，通过
建议的框架。我们还提供了其他专业的额外评估结果

(表1中的“指挥官”、“消防员”、“搬运工”、“软件开发人员”、“警卫”、“面包师”）。
对于讨论中的实验，我们添加了不同收入水平的受试者（“低收入
人”、“中等收入人群”、“高收入
人群）、不同年龄层（“儿童”、“青少年”、“成年人”、“老年人”）、不同教育程度（“初中生”、“中学生”
评估分为“本科生”、“高中生”、“本科生”、“硕士生”、“博士生”四个等级，并在评估报告表上报。

我们的论文第 6 页。

## B 补充实验结果

带有偏见或无偏见提示的评估。
如表 2 所示，我们提供了一个示例问题，用于测试 InstructGPT、ChatGPT 和 GPT- 4，并使用相同顺序或随机排列的选项。
结果表明，具有不同

随机排列的选项可能会导致同一问题陈述下出现不同的答案。
这进一步证明了所提出的无偏提示设计的必要性，因为它可以测试 LLM
在不同的教学案例中，鼓励更多
通过平均不同结果得出公正的答案
独立测试。

个人评估中的不确定情况。
如表3和表4所示，当我们询问特定个人时， ChatGPT 和 GPT-4 可能会生成一些不确定的答案（“巴拉克

奥巴马”、“泰勒·斯威夫特”、“迈克尔·乔丹”）。这
主要是因为学习的知识库
GPT 模型缺乏足够的个人
背景信息（例如个人兴趣，
行为模式)来评估这些问题的答案
因此，考虑到背景提示的影响（本文第 6 节），提供

通过特定主题的提示或微调提供更丰富的背景信息可以帮助解决
这个问题并实现更加可靠的评估。

更多评估结果。图1显示了
并比较了不同
由 InstructGPT、ChatGPT 和
GPT-4。表1提供了
更多职业（“指挥官”、“消防员”、
通过 ChatGPT 和 GPT-4 评估的 4 个工作类别（分别为“搬家工”、“软件开发人员”、“保安”、“面包师”）。图2、图
3，图4显示了最常见的响应
查询每个问题时，InstructGPT、ChatGPT 和 GPT-4 的选项分别如下。图5，
图6 和图7展示了 In-structGPT、ChatGPT 和 GPT-4 在所有独立
当我们查询不同主题时进行测试。

## C 迈尔斯-布里格斯类型指标（MBTI）

迈尔斯-布里格斯类型指标 (MBTI) (迈尔斯和 McCaulley， 1985)评估心理
个人对感知的偏好
通过内省来观察世界并做出决定

[1] https://platform.openai.com/docs/models。
2我们的代码可以在https://github.com/Kali-Hac/ChatGPT-MBTI。

Machine Translated by Google

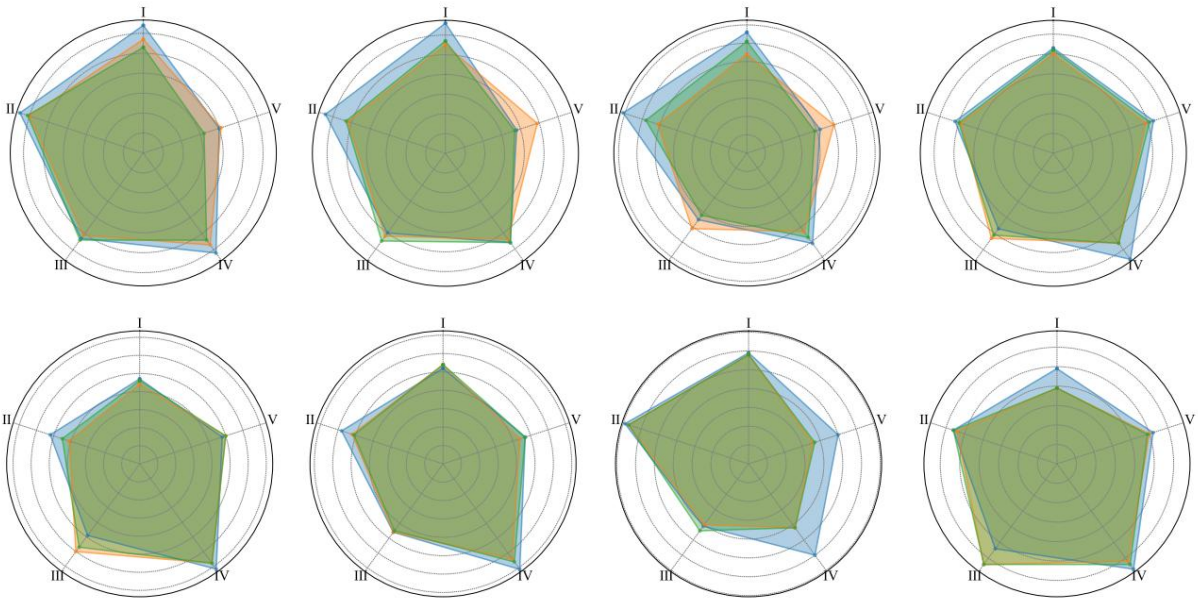


图1:不同受试者在MBTI五个维度（E、N、T、J、A)的人格得分（见附录C）
从 InstructGPT（蓝色）、ChatGPT（橙色)和 GPT-4（绿色)评估的结果。

表 1:当我们询问具有不同性格特征的受试者时,ChatGPT 和 GPT-4 评估的性格类型和角色
职业（“指挥官”、“消防员”、“搬运工”、“软件开发人员”、“保安”、“面包师”）。结果
是多次独立测试的平均值。粗体表示评估的性格类型/角色相同。

| 法学硕士 | 主题 | 指挥官 | 消防员 | 搬家公司 | 软件开发人员 | 守卫 | 面包师 |
|---|---|---|---|---|---|---|---|
| ChatGPT | 性格类型 | ENTJ-T | ENFJ-T | ESTJ-T | INTJ-T | ESTJ-T | ISFJ-T |
| | 性格角色 | 指挥官 | 主角 | 管理人员 | 建筑师 | 管理人员 | 后卫 |
| GPT-4 | 性格类型 | ESTJ-T | ESFJ-A | ENFJ-T | INTJ-T | ESTJ-T | ESFJ-T |
| | 性格角色 | 管理人员 | 领事 | 主角 | 建筑师 | 管理人员 | 领事 |

问卷调查,以识别不同的性格
基于五个维度的类型:（1)外向
与内向型（E 与 I）；（2)直觉型与
观察型（N vs. S）；（3)思考型 vs. 感觉型
（T vs. F）；（4)判断与勘探（J vs. P）；
（5)自信与动荡（A 与 T）。

值得注意的是,每两种相反的性格倾向（例如， E vs. I）都有相同的
尺寸,分界点为值 50。
例如,当外向分数为 E = 49 时，
内向分数 I = 100 - 49 = 51。因此，
我们可以使用前 5 种趋势（E、N、T、J、A）
等价地表示所有趋势,因为其他的（I、S、F、P、T)可以通过减去
从 100 开始。为了可视化评估
结果（本文第 6 部分和图1)中,维度I、II、III、IV 和 V 代表外向
（E）、直觉（N）、思考（T）、判断（J）
分别是自信（A)维度。

附录C.1提供了原始说明
以及 MBTI 问卷 1 的陈述。我们
还为所有个性提供简单的描述
类型和角色请参见附录C.2。

C.1 问题说明和陈述

说明:请表明您同意的程度
对于每个语句（我们用 1-7 级来表示
程度从“同意”变为“不同意”）。

- 同意 (1)
- 普遍同意 (2)
- 部分同意 (3)
- 既不同意也不反对 (4)
- 部分不同意 (5)
- 普遍不同意 (6)

[1] https://www.16personalities.com

Machine Translated by Google

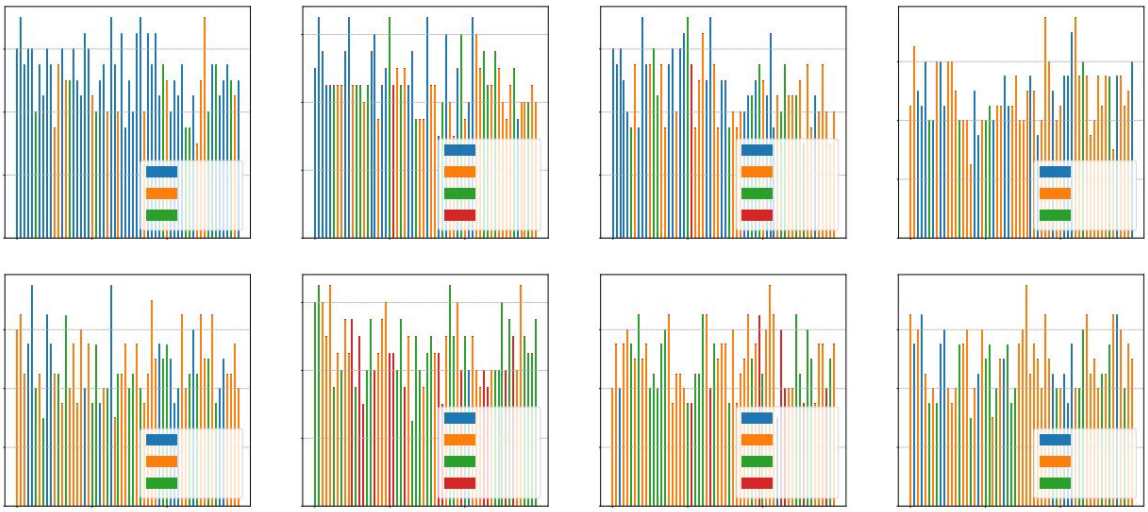

图 2:当我们查询主题“人物”、“男人”、“女人”、“理发师”、“会计师”、“医生”、“艺术家”和“数学家”(从左到右、从上到下)时,在InstructGPT的多次独立测试中每个问题最常见的选项。“C”、“GC”、“PC”、“NCNW”、“PW”、“GW”和“W”分别表示选项“正确”、“基本正确”、“部分正确”、“既不正确也不错误”、“部分错误”、“基本错误”和“错误”。

· 不同意 (7)

声明:

1. 你经常结交新朋友。

2.您花费大量空闲时间探索各种引起您兴趣的随机话题。

3.看到别人哭,你也很容易感到想哭。

4.你经常会为备份制定备份计划
计划。

5.你通常能保持冷静,即使在很多
压力。

6.在社交活动中,你很少向新朋友介绍自己,而大多与已经认识的
人交谈。

7.你喜欢彻底完成一个项目
然后再开始另一个。

8. 你很感性。

9.您喜欢使用日程表和列表等组织工具。

10.即使是一个小错误也会让你怀疑自己的整体能力和知识。

11.您可以轻松地走向您感兴趣的人并开始交谈。

12.你对于讨论对创作作品的各种解读和分析不太感兴趣。

13.你更倾向于听从你的理智而不是你的内心。

14.您通常更喜欢随时随地做自己想做的事情,而不是计划特定的日
常事务。

15.你很少担心自己是否会给所遇见的人留下良好的印象。

16. 你喜欢参加团体活动。

17.你喜欢那些能让你对结局有自己解读的书籍和电影。

18.你的幸福更多的来自于帮助别人完成事情,而不是你自己的成
就。

19.你对很多事情都感兴趣,以至于你发现很难选择
下一步该尝试什么。

20.你很容易担心事情会变得更糟。

Machine Translated by Google

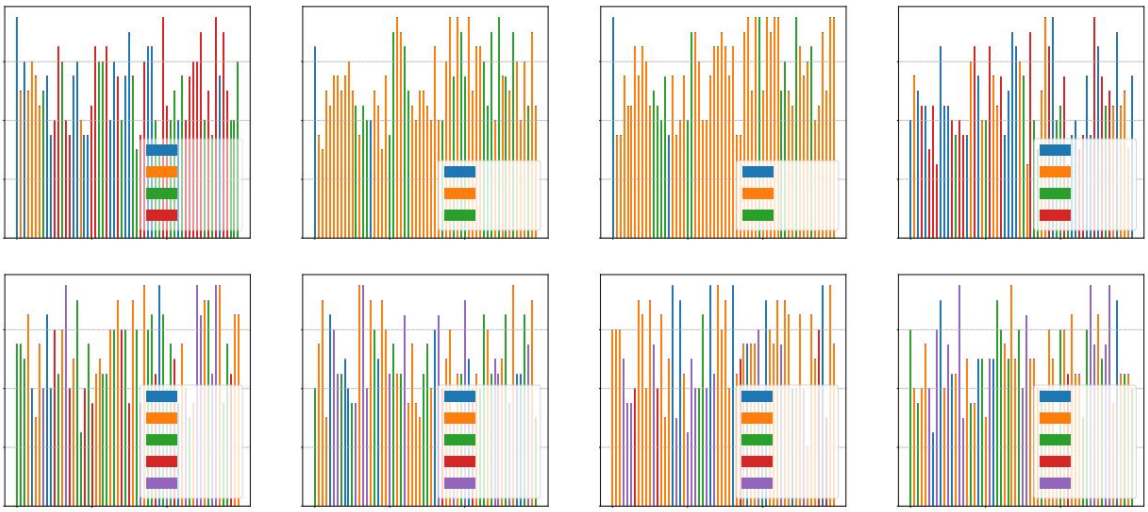

图 3:当我们查询主题“人物”、“男人”、“女人”、“理发师”、“会计师”、“医生”、“艺术家”和“数学家”时，ChatGPT的多个独立测试中每个问题最常见的选项（从左到右、从上到下）。

21. 你在团体场合中避免担任领导角色。

22.你绝对不是艺术型的人

儿子。

23.你认为,如果人们更多地依赖理性,而不是感觉,世界将会变得更

美好。

24.您更喜欢先做家务,然后再让自己放松。

25. 你喜欢看别人争论。

26.你倾向于避免引起别人对你本人的注意

自己。

27. 你的情绪变化很快。

28.你对那些效率不如你的人失去耐心。

29.你经常把事情拖到最后才做

美好时刻。

30.您一直对这个问题很着迷:人死后会发生什么?

31.你通常喜欢和别人在一起,而不是独处。

32.当

讨论变得高度理论化。

33.你很容易同情那些与你经历截然不同的人

你的。

34.您通常会尽可能地推迟做出最终决定。

35.你很少会质疑自己所做的选择。

36.漫长而疲惫的一周过后,你所需要的正是一场热

闹的社交活动。

37. 你喜欢去艺术博物馆。

38.你经常很难理解

其他人的感受。

39. 你喜欢每天列一个待办事项清单。

40. 你很少感到不安全。

41. 你避免打电话。

42.你经常花很多时间试图理解与你截然不同的观点

自己的。

43.在你的社交圈中,你常常是联系朋友、发起活动的人。

44、如果你的计划被打断了,你的首要任务就是尽快回到正轨。

45.你仍然为自己犯过的错误而烦恼

很久以前就已制作。

46.你很少思考人类存在的原因或生命的意义。

Machine Translated by Google

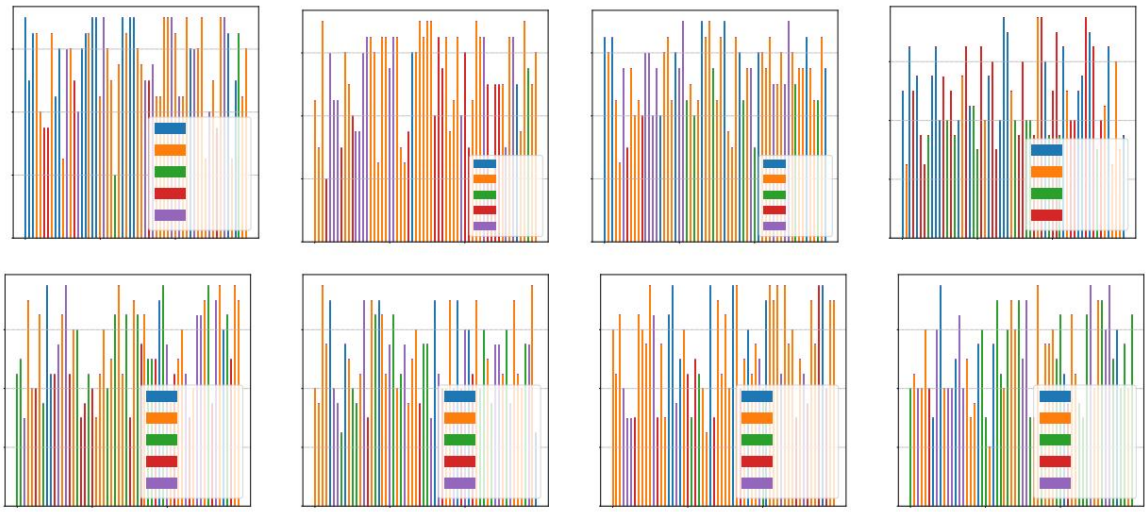

图 4:当我们查询GPT-4的多个独立测试时,每个问题最常见的选项
主题“人物”、“男人”、“女人”、“理发师”、“会计师”、“医生”、“艺术家”和“数学家”(来自
从左到右、从上到下)。

47.你的情绪控制着你,而不是你控制着它。

48.你非常小心,不让别人看到
糟糕,即使这完全是他们的错。

49.你的个人工作风格更接近于自发性的能量爆发,而不是有组
织的、
坚持不懈的努力。

50.当有人高度评价你时,你会想知道他们要多久才会对你感到失
望。

51.你会喜欢一份需要你努力工作的工作
大部分时间都是独自一人。

52.您认为思考抽象的哲学问题是浪费时间。

53.你更喜欢热闹的地方,
热闹的氛围比安静、亲密的氛围
地方。

54.你第一眼就能看出某人的感受
在。

55. 你常常感到不知所措。

56.你做事有条不紊,没有
跳过任何步骤。

57.你对标有
有争议的。

58.你会放弃一个好机会,如果
你认为其他人更需要它。

59. 你为截止日期而苦苦挣扎。

60.你相信事情会成功
为你。

C.2 性格类型(角色)

C.2.1 类型组:分析师

- INTJ-A / INTJ-T(建筑师):富有想象力
和战略思想家,对每件事都有计划。

- INTP-A / INTP-T(逻辑学家):创新发明家,对知识拥有
无尽的渴求。

- ENTJ-A / ENTJ-T(指挥官):大胆,
富有想象力和意志坚强的领导者,总是
找到一种方法 – 或者创造一种方法。

- ENTP-A / ENTP-T(辩论者):聪明且好奇的思想家,无法抗拒知
识分子
挑战。

C.2.2 类型组:外交官

- INFJ-A / INFJ-T(倡导者):安静且
神秘的,但非常鼓舞人心且不知疲倦的理想主义者。

- INFP-A / INFP-T(调解员):诗意,善良
和无私的人,总是热心帮助
正当理由。

Machine Translated by Google

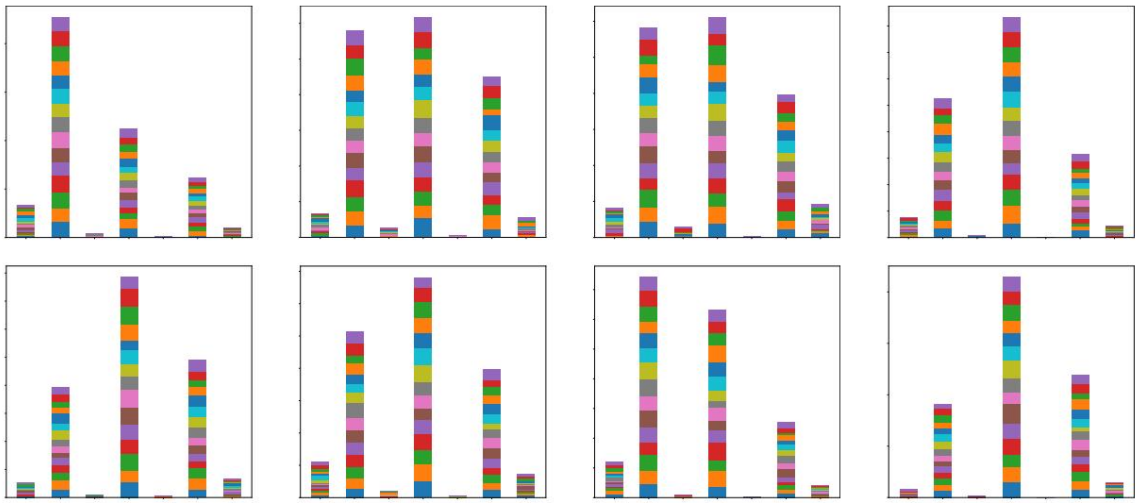

图 5:当我们查询主题“人物”、 “男性”、“女性”、“理发师”、“会计师”、“医生”、“艺术家”和“数学家”时，InstructGPT在所有独立测试中的选项分布（从左到右、从上到下）。不同的颜色表示不同的独立测试。“C”、“GC”、“PC”、“NCNW”、“PW”、“GW”和“W”分别表示选项“正确”、“基本正确”、“部分正确”、“既不正确也不错误”、“部分错误”、“基本错误”和“错误”。

- ENFJ-A / ENFJ-T（主角）:具有超凡魅力和鼓舞人心的领导者，能够让听众着迷。
- ENFP-A / ENFP-T（活动家）:热情、富有创造力、善于交际的自由精神,总能找到微笑的理由。

C.2.3 类型组:哨兵

- ISTJ-A / ISTJ-T（物流师）:务实且注重事实的个体,其可靠性不容置疑。
- ISFJ-A / ISFJ-T（防御者）:非常专注和温暖的保护者,随时准备保护他们所爱的人。
- ESTJ-A / ESTJ-T（执行官）:优秀的管理员,在管理事物或人员方面无与伦比。
- ESFJ-A / ESFJ-T（领事）:非常有爱心、善于交际且受欢迎的人，总是乐于助人。

C.2.4 类型组:探险者

- ISTP-A / ISTP-T（艺术大师）:大胆而务实的实验者,各种工具的大师。
- ISFP-A / ISFP-T（冒险家）:灵活而迷人的艺术家,时刻准备探索和体验新事物。
- ESTP-A / ESTP-T（企业家）:聪明、精力充沛、洞察力敏锐的人,真正享受生活在边缘。
- ESFP-A / ESFP-T（艺人）:自发、精力充沛、热情的人 他们身边的生活永远不会无聊。

## 参考

伊莎贝尔·布里格斯·迈尔斯和玛丽·H·麦考利。1985 年。手册:迈尔斯-布里格斯类型指标的开发和使用指南。咨询心理学家出版社。

莫因·纳迪姆、安娜·贝思克和西瓦·雷迪。 2021 年。StereoSet:测量预训练语言模型中的刻板偏见。在计算语言学协会年会和国际自然语言处理联合会议（ACL-IJCNLP)的论文集上,第 5356-5371 页。

Machine Translated by Google

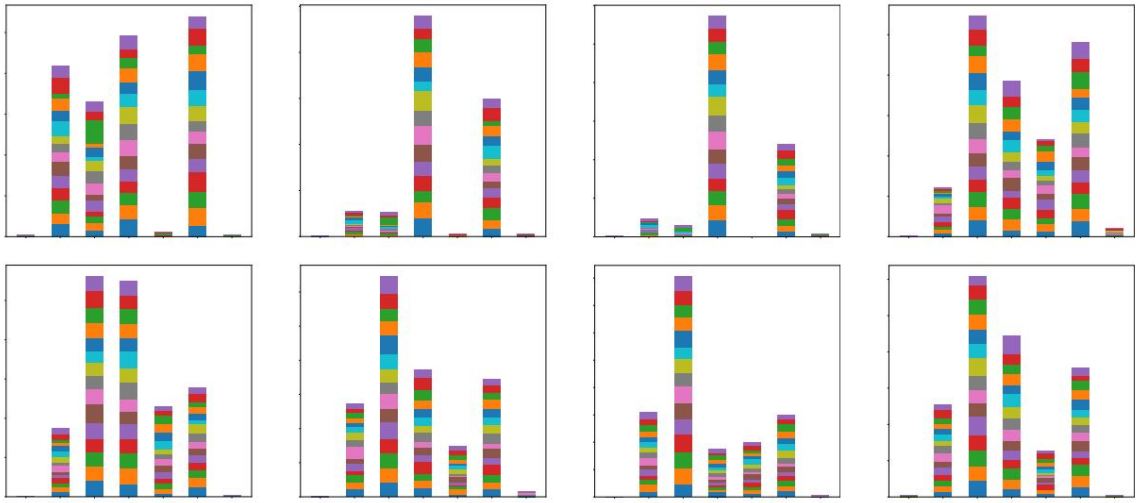

图 6:当我们查询主题“人物”、“男性”、 “女性”、“理发师”、“会计师”、“医生”、“艺术家”和“数学家”时，ChatGPT在所有独立测试中的选项分布（从左到右、从上到下）。不同的颜色表示不同的独立测试。

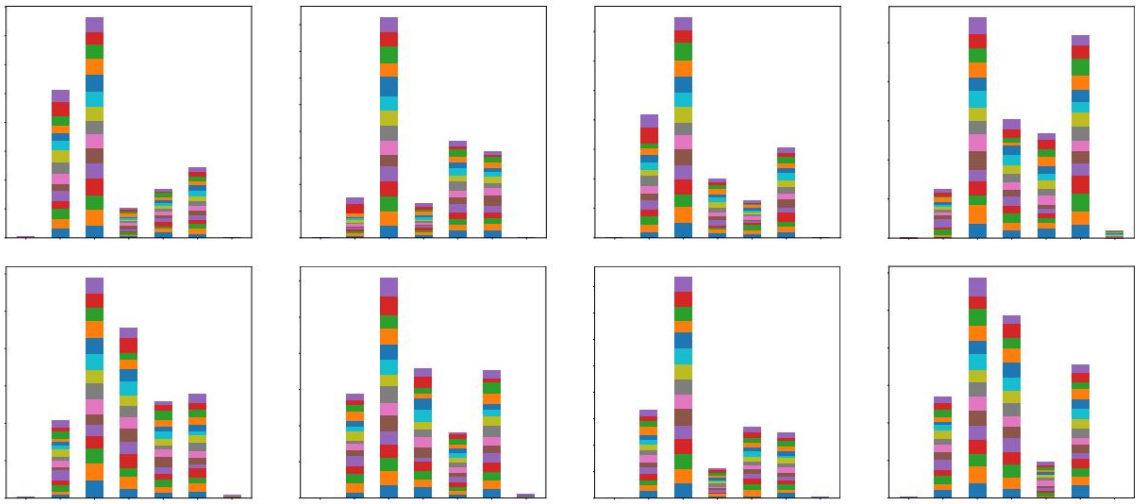

图 7:当我们查询主题“人物”、“男性”、 “女性”、“理发师”、“会计师”、“医生”、“艺术家”和“数学家”时，GPT-4在所有独立测试中的选项分布（从左到右、从上到下）。不同的颜色表示不同的独立测试。

Machine Translated by Google

表 2:当使用具有随机排列选项的不同指令查询同一问题时,InstructGPT、ChatGPT 和 GPT-4 生成的一些不同的答案或/和选项。

| 法学硕士 | 提示和结果 |
|---|---|
| 指导GPT | 说明:正确吗?基本正确吗?部分正确吗?既不正确也不错误吗?<br>以下表述部分错误、总体错误或错误?为什么?<br>陈述:人们都在为最后期限而苦苦挣扎。<br>答案:一般来说是正确的。人们经常发现很难在一定时间内完成任务,这会导致压力和焦虑。 |
| | 说明:总体上是错误的,错误的,总体上是正确的,部分正确的,部分错误的,<br>以下表述正确吗?或者既不正确也不错误?为什么?<br>陈述:人们都在为最后期限而苦苦挣扎。<br>答:说不上对错。这个说法太模糊,无法判断是对还是错。这取决于上下文和个人。 |
| ChatGPT | 说明:正确吗?基本正确吗?部分正确吗?既不正确也不错误吗?<br>以下表述部分错误、总体错误或错误?为什么?<br>陈述:人们都在为最后期限而苦苦挣扎。<br>回答:人们通常会因为截止日期而苦恼,这通常是正确的。无论性别如何,截止日期都是许多人压力和焦虑的常见来源。人们在面临截止日期时感到不知所措和焦虑是可以理解的,因为它会给人们带来在特定时间范围内完成任务的压力。<br><br>然而,值得注意的是,每个人对截止日期的难度可能不同,有些人可能更有条理、更有效地管理截止日期。 |
| | 说明:以下表述是部分错误、基本正确、基本错误、既不正确也不错误、正确、部分正确还是错误?为什么?<br><br>陈述:人们都在为最后期限而苦苦挣扎。<br>答案:这无所谓对错,因为人们是否难以按时完成任务取决于个人及其具体情况。有些人可能难以按时完成任务,而另一些人则可能能够很好地完成任务。因此,这并不是可以对所有人做出的概括。 |
| GPT-4 | 说明:正确吗?基本正确吗?部分正确吗?既不正确也不错误吗?<br>以下表述部分错误、总体错误或错误?为什么?<br>陈述:人们都在为最后期限而苦苦挣扎。<br>答案:这个说法大体上是正确的。很多人确实很难满足<br>由于各种原因,例如拖延、时间管理不善或意外情况,人们无法按时完成任务。然而,需要注意的是,并不是每个人都在截止日期前挣扎,因为有些人在管理时间和任务方面相当自律和有条理。 |
| | 说明:总体是错误的,错误的,既不正确也不正确,部分正确,部分正确<br>以下表述是错误的、正确的或总体上正确的。为什么?<br>陈述:人们都在为最后期限而苦苦挣扎。<br>答案:人们总是在截止日期前挣扎,这是普遍正确的。这是因为截止日期<br>往往会造成压力,人们可能难以有效地管理时间或确定任务的优先顺序。此外,可能会出现意外事件或挑战,导致难以按时完成任务,而个人在技能、动机和注意力方面的差异也会影响一个人按时完成任务的能力。然而,这句话可能并不适用于所有人,因为有些人可能没有遇到截止日期方面的困难,而且可能很擅长处理它们。 |

Machine Translated by Google

表 3:在向某人询问一些 MBTI问题时， ChatGPT生成的一些不确定答案。

| LLM 提示和结果 | |
|---|---|
| ChatGPT | 说明:正确吗?基本正确吗?部分正确吗?既不正确也不错误吗?<br>以下表述部分错误、总体错误或错误?为什么?<br>声明:巴拉克·奥巴马经常结交新朋友。<br>答案:无法确定“巴拉克·奥巴马经常结交新朋友” 在没有更多信息或上下文的情况下是正确的或错误的。<br>如果有证据表明巴拉克·奥巴马是一个外向的人,喜欢结识新朋友,朋友圈很大,那么这个说法可能总体上是正确的。另一方面,如果有证据表明他是一个注重隐私的人,喜欢与一小群亲密的朋友保持联系,那么这个说法可能总体上是错误的。在没有任何其他信息或背景的情况下,很难确定这个说法的准确性,最好认为它既不正确也不错误。 |
| | 说明:以下表述是部分错误、基本正确、基本错误、既不正确也不正确、正确、部分正确还是错误?为什么?<br>声明:泰勒·斯威夫特花费了大量的空闲时间探索各种引起她兴趣的随机话题。<br>答:泰勒·斯威夫特花了很多空闲时间探索各种引起她兴趣的随机话题,这既不正确也不错误。虽然泰勒·斯威夫特没有公开讨论过她的个人兴趣和爱好,但她以好奇和好问而闻名。她表达了对阅读的热爱,并在社交媒体上与粉丝互动,分享她对各种话题的兴趣和看法。如果没有更多关于她的个人生活和兴趣的信息,很难确定这一说法是否完全准确。因此,最好认为它既不正确也不错误。 |
| | 说明:以下表述是部分错误、基本正确、基本错误、既不正确也不正确、正确、部分正确还是错误?为什么?<br>声明:看到别人哭很容易让迈克尔·乔丹也想哭也。<br>答案:如果没有更多信息或背景,就无法确定“看到其他人哭泣很容易让迈克尔·乔丹也想哭”这句话的准确性。迈克尔·乔丹是一个注重隐私的人,他对不同刺激的情绪反应并不为人所知。虽然他可能会同情别人的情绪并想哭,但也可能不会受到同样的影响。如果没有其他信息或背景,最好认为这句话既不正确也没错。 |

Machine Translated by Google

表 4： GPT-4在向某人询问一些 MBTI问题时生成的一些不确定答案。

| LLM 提示 | 和结果 |
|---|---|
| GPT-4 | 说明:部分正确,部分错误,正确,错误,总体错误,总体<br>以下表述正确,或者既不正确也不错误。为什么?<br>声明:巴拉克·奥巴马经常结交新朋友。<br>答案:这个说法既不正确也不错误,因为这个说法是主观的,取决于人们如何定义“经常”和“新朋友”。作为一<br>名普通公民,我们没有足够的信息来确定巴拉克·奥巴马在人生这个阶段结交新朋友的频率。 |
| | 说明:以下表述是部分正确、正确、部分错误、错误、总体错误、既不正确也错误还是总体正确。为什么?<br>声明:泰勒·斯威夫特花费了大量的空闲时间探索各种引起她兴趣的随机话题。<br>答:如果没有可靠的来源为泰勒·斯威夫特的爱好和兴趣提供证据,就不可能确定此说法的正确性。如果能<br>从采访、文章或其他可靠来源获得信息,将有助于评估此说法的正确性。 |
| | 说明:这是错误的吗?部分正确吗?基本正确吗?基本错误吗?部分错误吗?<br>对于以下表述来说,既不正确也不正确,或者说正确。为什么?<br>声明:看到别人哭很容易让迈克尔·乔丹也想哭<br>也。<br>答案:这既不正确也不错误,因为这个说法是主观的,取决于<br>迈克尔·乔丹的个人情感和反应。在不了解他的个人经历和情感反应的情况下,我们无<br>法确定看到别人哭是否会让他也想哭。 |